

УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



Vedran Mitić 2123

SEMINARSKI RAD

Data Quality

Mentor:

prof. dr Aleksandar Stanimirović

2026.

Table of Contents

1. UVOD	4
1.1 Definicija i značaj kvaliteta podataka	4
1.2 Dimenzije kvaliteta podataka	5
1.3 Uticaj lošeg kvaliteta podataka na modele mašinskog učenja	6
2. STATISTIČKA KARAKTERIZACIJA I PROFILISANJE PODATAKA	7
2.1 Tipovi atributa i njihov uticaj na analizu kvaliteta	7
2.2 Mere centralne tendencije kao osnova validacije	8
2.3 Analiza varijanse i disperzije podataka	9
2.4 Momenti raspodele: Asimetrija (Skewness) i Spljoštenost (Kurtosis)	11
3. ANALIZA RASPODELE I NORMALNOST PODATAKA	12
3.1 Značaj normalne raspodele za statističke algoritme	12
3.2 Vizuelne metode dijagnostike	13
3.3 Statistički testovi normalnosti	14
4. ANALIZA KORELACIJE I REDUNDANTNOSTI	16
4.1 Mere sličnosti i različitosti podataka	16
4.2 Koeficijenti korelacije	17
4.3 Redundantni atributi i multikolinearnost	18
4.4 Kovarijansa i međuzavisnost varijabli	19
5. DETEKCIJA ANOMALIJA KAO INDIKATOR KVALITETA	20
5.1 Taksonomija anomalija: Šum (<i>Noise</i>) i Ekstremne vrednosti (<i>Outliers</i>)	20
5.2 Statistički pristupi detekciji <i>outlier</i> -a	21
5.3 Uticaj ekstremnih vrednosti na mere varijanse i korelacije	22
5.3.1 Uticaj na korelaciju i regresiju	22
5.3.2 Uticaj na t-test i ANOVA	22
5.3.3 Uticaj na procenu parametara	22
6. PREPORUKE ZA POBOLJŠANJE KVALITETA	23
6.1 Identifikacija potrebe za transformacijom podataka	23
6.2 Strategije za tretiranje identifikovanog šuma i anomalija	23
7. AUTOMATSKO MAŠINSKO UČENJE (AutoML)	24
7.1. Koncept automatizacije profilisanja	24
7.2. AutoML alati i tehnike predobrade	24

7.3. Industrijska rešenja: Cloud AutoML platforme	25
8. ZAKLJUČAK.....	26
LITERATURA.....	27

1. UVOD

Brzi razvoj tehnologija kao što su veštačka inteligencija, hibridni cloud, internet stvari i *Edge computing* proteklih godina uzrokovao je ekspanzivan rast velikih skupova podataka. Ovakav rast dodatno je zakomplikovao procese upravljanja matičnim podacima, namećući potrebu za strožim pravilima, većim angažovanjem *data steward*-a i unapređenim merama za obezbeđivanje kvaliteta podataka. Savremena nauka o podacima i mašinsko učenje počivaju na premisi da su podaci verni reprezent realnosti. Međutim, u praksi se često suočavamo sa fenomenom gde kompleksnost algoritama ne može da nadomesti nedostatke u samom skupu podataka. Razumevanje kvaliteta podataka nije samo statistički zadatak, već kritičan korak u inženjerskom procesu koji direktno određuje uspeh ili neuspeh prediktivnog modela. U ovom poglavlju biće definisani osnovni koncepti kvaliteta, istražiti dimenzije kroz koje se on meri, i objasniti fundamentalni princip koji diktira modernu analitiku – da su rezultati onoliko dobri koliko i ulazni materijal.

1.1 Definicija i značaj kvaliteta podataka

Kvalitet podataka je teško definisati u pogledu samostalnog pojma, jer podaci sami po sebi mogu imati različita značenja za različite korisnike ili ne moraju uopšte biti od značaja za neke korisnike. Bolje rečeno, kvalitet podataka zavisi od namene za koju se skup podataka koristi, a *podaci imaju kvalitet ukoliko zadovoljavaju potrebe predviđene upotrebe* [1]. Mere kvaliteta podataka su tačnost, kompletnost, doslednost, validnost, jedinstvenost, blagovremenost, interpretabilnost... Ove mere se uglavnom odnose na stanje kvalitativnih ili kvantitativnih informacija u skupu podataka. Provera kvaliteta je prva faza procesa otkrivanja znanja iz baza podataka, bez koje su sve ostale faze (*data mining*, evaluacija) kompromitovane, a u realnim situacijama, preko 60% vremena se utroši na proveru i pripremu podataka, a manji procenat na samo modelovanje.

Zbog ogromne količine podataka i njihove integracije iz više različitih izvora, savremene baze podataka često sadrže nepotpune, neprecizne i međusobno neusaglašene informacije. Ovakve informacije se javljaju u vidu šumova, nedostajućih i nekonzistentnih podataka ili *outliera*, a mogu biti proizvod ljudskih ili kompjuterskih grešaka. Na primer, ispitanici formulara često namerno upišu lažne podatke zbog zabrinutosti o privatnosti, ostave neobavezna polja praznim ili iz nekog razloga podnesu polovično nedovršene informacije. Podaci koji u skupu podataka postoje kao legitimni, ali imaju ulogu *placeholder*-a se nazivaju „prekriveni nedostajući podaci” (*DMV - Disguised missing data*). Kompjuterska greška se može javiti na primer u vidu torke duplikata. Takav kvalitet podataka negativno utiče na pouzdanost i tačnost rezultata dobijenih primenom tehnika rudarenja podataka i algoritama mašinskog učenja. Poboljšanje kvaliteta podataka postiže se njihovom preobradom kao što su *Data cleaning*, *Data reduction*, *Data transformation*, *Data selection*... Sve ove tehnike predstavljaju posebnu temu za izučavanje i mogu doprineti povećanju tačnosti i efikasnosti algoritama, ali sem površnih dodirivanja neće biti detaljnije obrađene u ovom seminarskom radu.

1.2 Dimenzije kvaliteta podataka

U prethodnom podpoglavlju dimenzije kvaliteta podataka su nabrojane u vidu mera kvaliteta. Sledi opis svake od njih:

- **Tačnost** (*Accuracy*) – predstavlja verodostojnost podataka i odgovara na pitanje koliko blizu se podatak poklapa sa svojom pravom vrednošću u stvarnom svetu? Tačni podaci su ispravni, precizni i bez grešaka. U koloni koja sadrži godine radnog staža može se pronaći vrednost 200, što je najverovatnije greškom ukucano 20. Statistički, ovo je će biti okarakterisano *outlier*-om jer je broj 200 nemoguć za godine radnog staža – podataka je numerički ispravan, ali je netačan jer ne oslikava stvarnost.
- **Kompletnost** (*Completeness*) – odgovara na pitanje koliko su podaci potpuni, odnosno da li ima podataka koji nisu prikupljeni. Ako je bilo potrebno da se prikupe ime i *e-mail* adresa ispitanika, a *e-mail* nedostaje, onda su podaci nekompletni jer je teško stupiti u kontakt sa ispitanikom samo na osnovu imena. Poseban izazov ovde predstavljaju *DMV*, gde polja nisu prazna, već sadrže generičke vrednosti (*placeholders*) koje maskiraju nekompletnost.
- **Doslednost** (*Consistency*) – odsustvo protivrečnosti unutar istog skupa podataka ili između različitih izvora podataka. Podaci su konzistentni ako ista informacija ima istu vrednost i format kroz ceo sistem. Najprostiji primer jeste način beleženja datuma u skupu podataka, gde se u nekim slučajevima beleži u formatu *DD/MM/YYYY*, a u nekim *MM/DD/YYYY*.
- **Blagovremenost** (*Timeliness*) – vremenska relevantnost podataka u odnosu na trenutak njihove upotrebe. U vremenski osetljivim sistemima i najmanja kašnjenja od par sekundi (zakasnelo očitavanje sa senzora) nose podatke niskog kvaliteta blagovremenosti jer je vreme za donošenje odluke već prošlo.
- **Verodostojnost** (*Believability*) – odgovara na pitanje koliko korisnik veruje podacima. Ovo je više subjektivna nego tehnička mera. Korisnik može preispitivati verodostojnost podataka na osnovu izvora iz kojih potiču ili nelogičnosti koje je uočio (npr. trudan muškarac).
- **Interpretabilnost** (*Interpretability*) – odgovara na pitanje sa koliko su podaci razumljivi. Nedefinisani nazivi kolona i kodirane vrednosti mogu biti beznačajne za korisnika koji ne zna šta one predstavljaju. Različiti nazivi jednog istog objekta za model mašinskog učenja predstavljaju različite kategorije.
- **Validnost** (*Validity*) – određuje u kojoj meri podaci poštuju definisana pravila, formate i logička ograničenja predviđena za skup podataka. Na primer da li je vrednost ocene u ograničenju od 5 do 10, broj cifara JMBG jednak 13 (u Srbiji), format unosa jednak očekivanom formatu (datum), unešen neočekivan tip podatka...
- **Jedinstvenost** (*Uniqueness*) – osigurava da se svaki entitet u skupu podataka pojavljuje samo jednom, odnosno da nema duplikata. Može se dogoditi da je korisnik napravio dva korisnička naloga korišćenjem dva različita načina za registrovanje i time uzrokovao postojanje dva ista entiteta sa različitim identifikatorima u skupu podataka.

Sve navedene dimenzije kvaliteta nisu izolovane; one se često preklapaju i međusobno uslovljavaju. Na primer, niska validnost (pogrešan format) često vodi do nekompletnosti (sistem ne može da očita podatak), dok narušena jedinstvenost može stvoriti lažnu sliku o

tačnosti određenih trendova. Za inženjera podataka, ove dimenzije predstavljaju kontrolnu listu (checklist) koju je neophodno proći pre nego što se podaci povere algoritmu.

1.3 Uticaj lošeg kvaliteta podataka na modele mašinskog učenja


Razumevanje gde i kako podaci otkazuju u ovim kategorijama omogućava nam da predvidimo probleme koji će se javiti u fazi treniranja modela, što nas dovodi do fundamentalnog principa savremene analitike – **GIGO (Garbage In, Garbage Out) principa**. *GIGO* princip nalaže da kvalitet izlaznih rezultata modela direktno zavisi od kvaliteta ulaznih podataka. Čak i najsofisticiraniji algoritmi, poput dubokih neuronskih mreža, ne mogu kompenzovati suštinske nedostatke u skupu podataka; naprotiv, loš kvalitet podataka često biva pojačan kroz proces učenja. Na primer, prisustvo šuma i outliera direktno narušava pretpostavke algoritama kao što je linearna regresija, gde ekstremne vrednosti mogu drastično pomeriti regresionu liniju i dovesti do pogrešnih predviđanja.

Uticaj lošeg kvaliteta manifestuje se kroz nekoliko kritičnih aspekata:

- **Pristrasnost modela (*Bias*)** - Nekompletni ili nejedinstveni podaci mogu navesti model da nauči pogrešne pravilnosti, favorizujući određene grupe podataka koje su veštački zastupljenije.
- **Smanjena preciznost i pouzdanost** - Netačni i nekonzistentni podaci povećavaju stopu greške, čineći model neupotrebljivim u realnim okruženjima gde je preciznost od vitalnog značaja (npr. medicina ili finansije).
- **Matematička nestabilnost** - Problemi poput heteroskedastičnosti (nestabilne varijanse) ili multikolinearnosti (redundantnosti), o kojima će biti reči u kasnijim poglavljima, direktno otežavaju konvergenciju algoritama i interpretaciju rezultata.

Ukoliko se problemi sa podacima, kao što su duplikati, nedostajuće vrednosti i outlajeri, ne rešavaju na adekvatan način, organizacije povećavaju rizik od negativnih poslovnih ishoda. Prema izveštaju kompanije Gartner, loš kvalitet podataka organizacije u proseku košta oko 12,9 miliona američkih dolara godišnje [9].

U suštini, loš kvalitet podataka dovodi do nepoverenja u rad modela, jer rezultati postaju nepredvidivi i statistički neopravdani. Zbog toga identifikacija i dijagnostika problema kvaliteta ne predstavljaju samo pripremnu fazu, već esencijalni deo razvoja robusnog i etički ispravnog modela mašinskog učenja.



Slika 1. Lanac halucinacije modela [11]

2. STATISTIČKA KARAKTERIZACIJA I PROFILISANJE PODATAKA

Skupovi podataka se sastoje od objekata podataka, ili češće nazvanih instance, uzorci, observacije ili entiteti (i mnogi drugi nazivi). Uzorci se opisuju sinonimima: atributima, karakteristikama, dimenzijama, odlikama (*features*)... Preciznije, *atribut predstavlja osobinu ili karakteristiku objekta koja može da varira, bilo od objekta do objekta ili s vremena na vreme* [2], a *measurment scale je funkcija koja povezuje numeričku ili simboličku vrednost sa atributom objekta* [2].

Pre nego što se primene kompleksni algoritmi mašinskog učenja, neophodno je izvršiti **statističko** profilisanje tih atributa. Ovaj proces nam omogućava da razumemo "prirodu" podataka: gde se nalazi njihova sredina, koliko variraju i kakvog je oblika njihova raspodela. Bez ovakve karakterizacije, nemoguće je identifikovati anomalije ili doneti ispravnu odluku o transformaciji podataka. Prvi i najvažniji korak u tom procesu je identifikacija tipova atributa, jer upravo od prirode samog atributa zavisi koji će matematički aparat i koja mera kvaliteta biti primenjena.

2.1 Tipovi atributa i njihov uticaj na analizu kvaliteta

Tip atributa (ili tip podatka) može se definisati kao skup vrednosti koje atribut može imati, zajedno sa skupom operacija koje su nad tim vrednostima dozvoljene. U statističkom smislu, tip atributa nam govori o prirodi informacija koje on nosi i određuje matematički okvir unutar kojeg se taj atribut može analizirati. Identifikacija tipa je kritična jer ona postavlja semantička ograničenja: tip podatka nam sugeriše da li operacije poput sabiranja, rangiranja ili računanja proseka imaju logičkog smisla. Na primer, dok sabiranje dve vrednosti prihoda daje jasnu informaciju, sabiranje dva poštanska broja je matematički moguće, ali informativno besmisleno. Iz inženjerske perspektive, tip atributa je prvi filter u dijagnostici kvaliteta, jer on diktira izbor vizuelnih metoda (*histogram* ili *bar chart*) i statističkih testova koji će se koristiti u daljem profilisanju.

- **Kategorički (Kvalitativni) tip atributa:**

- **Nominalni** – vrednosti atributa su predstavljenje simbolima ili nazivima koje predstavljaju neku kategoriju, regiju, osobinu, itd. I nemaju neki značajan redosled. Pod simbolima se ne mora striktno vezivati za slovne znakove – primer nominalnog tipa jeste i *ID*, koji se najčešće označava brojevima gde je svaki *ID* jedinstven. Ovakav tip podatka služi isključivo za razlikovanje uzoraka (= ili $\neq$).
- **Ordinalni** – vrednosti atributa imaju logički redosled kategorija, ali razlike između tih kategorija nisu određene. Drugim rečima, vrednosti pružaju dovoljno informacija samo za uređivanje (ordering) uzoraka (< ili >). Na primer, činovi u vojsci su jasno poređani od oficira do generala, ali ne možemo objektivno da znamo koje su razlike između činova.
- **Binarni** – nominalni atributi koji mogu imati samo dve moguće vrednosti: **0** ili **1**. Ovime se može reprezentovati prisutnost/odsustvo, tačnost/netačnost, pol, da/ne... Generalno, svaka kategorizacija koja je moguća da se opiše jedino dvojčano. Mogu biti simetrični, ukoliko su i 0 i 1 od podjednakog značaja (iste težine), ili asimetrični, ukoliko je bitno šta predstavlja 1, a šta predstavlja 0.

- **Numerički (Kvantitativni) tip atributa:**

- **Intervalni (*Interval-scaled*)** – mogu biti kontinualne ili diskretne uređene vrednosti, s tim što su razlike između njih merljive. Takođe mogu imati i negativne i nula vrednosti (ne označava odsustvo). Razlike su određene mernim jedinicama (npr. dani, milimetri, stepeni celzijusa...).
- **Racijalni (*Ratio-scaled*)** – razlika je u odnosu na intervalne što postoji apsolutna nula, a odnosi (proporcije) između vrednosti su smisleni (npr. masa, cena, broj prodatih artikala, temperatura u Kelvinima...).

2.2 Mere centralne tendencije kao osnova validacije

Nakon identifikacije tipova atributa, sledeći korak u profilisanju podataka je primena mera centralne tendencije. Ove mere imaju za cilj da jednim brojem opišu 'centar' ili tipičnu vrednost raspodele podataka, pružajući brz uvid u opšte karakteristike uzorka. Međutim, u kontekstu analize kvaliteta, mere centralne tendencije služe kao primarni alat za validaciju i inicijalnu detekciju anomalija. Poređenjem srednje vrednosti, medijana i modusa, analitičar može naslutiti prisustvo outliera, asimetriju raspodele ili greške u prikupljanju podataka. Na primer, drastično odstupanje srednje vrednosti od medijana često je prvi signal da u podacima postoje ekstremne, netačne vrednosti koje 'vuku' prosek i time kompromituju budući model mašinskog učenja. Stoga, ove mere ne predstavljaju samo deskriptivnu statistiku, već osnovu na kojoj se gradi dijagnoza validnosti i pouzdanosti čitavog skupa podataka.

- **Srednja vrednost (*Mean*)** – pod srednjom vrednošću misli se na aritmetičku sredinu skupa vrednosti, koja se prosto izračunava formulom:

$$\bar{x} = \frac{\sum_{i=1}^N x_i}{N} \quad (1)$$

Gde je N broj vrednosti, a x_i vrednost i-tog uzorka.

Mana ove mere je njena velika osetljivost na outlajere. Ukoliko se u skupu podataka pojavi ekstremno visoka ili niska vrednost, srednja vrednost će se drastično pomeriti, pružajući lažnu sliku o proseku. Iz tog razloga, nekada se koristi *trimmed mean* – srednja vrednost bez uzimanja u obzir ekstremnih vrednosti.

- **Medijan (*Median*)** – središnja vrednost u uređenom nizu podataka koja deli podatke na gornju i donju polovinu. Za razliku od srednje vrednosti, medijan je robusna mera. To znači da ekstremne vrednosti nemaju uticaj na njega. Na primer, ako plata jednog radnika skoči sa 1.000 na 100.000 evra zbog greške u kucanju, medijana će ostati ista ili se minimalno promeniti. Mana ove mere je računarska zahtevnost izračunavanja kada imamo veliki broj uzoraka. Aproksimacija vrednosti medijana:


$$median = L_1 + \left(\frac{\frac{N}{2} - (\sum freq)_l}{freq_{median}} \right) width \quad (2)$$

Gde je L_1 donja granica medianog intervala, N ukupan broj vrednosti u skupu podataka, $(\sum freq)_l$ suma učestalosti svih intervala koji se nalaze ispod medianog intervala, $freq_{median}$ je učestalost intervala medijana i *width* je širina medianog intervala.

- **Modus (Mode)** - vrednost koja se najčešće pojavljuje u skupu podataka. Za razliku od prethodne dve mere, modus se može primeniti i na numeričke i na nominalne attribute. Skup podataka može imati jedan modus (*unimodal*), više modusa (*multimodal*) ili nijedan (ako se sve vrednosti pojavljuju podjednako često). Modus je ključan za proveru konzistentnosti i validnosti kategoričkih podataka. Na primer, ako analiziramo kolonu „Grad“, a modusi su „Beograd“ i „BEOGRAD“, odmah uočavamo problem u kvalitetu (nedosledno pisanje velikih slova). Takođe, kod numeričkih podataka, neočekivano visoka frekvencija određene vrednosti može ukazati na to da se ta vrednost koristi kao *placeholder* za nedostajuće podatke. Za unimodalan skup podataka, ukoliko je poznata vrednost *mean*-a i *median*-a, može se aproksimirati *mode* preko formule:

$$mean - mode \approx 3 * (mean - median) \quad (3)$$

- **Srednji opseg (Midrange)** – srednja vrednost najveće i najmanje vrednosti u skupu podataka.



Slika 2. Grafička reprezentacija razlike između mode-a, median-a i mean-a [12]

2.3 Analiza varijanse i disperzije podataka

Iako mere centralne tendencije daju uvid u to gde se podaci grupišu, one same po sebi nisu dovoljne za potpunu karakterizaciju skupa podataka. Dva skupa podataka mogu imati identičnu srednju vrednost, a ipak se dramatično razlikovati u pogledu svoje strukture i pouzdanosti. Ovde na scenu stupa analiza varijanse i disperzije podataka (raspršenosti). Ove mere kvantifikuju koliko uzorci odstupaju od svoje sredine, odnosno koliko je skup podataka homogen ili heterogen. U inženjerstvu podataka, visoka disperzija često je indikator nestabilnosti procesa prikupljanja podataka ili prisustva značajnog šuma. Razumevanje varijabiliteta je od presudnog značaja za postavljanje granica normalnog ponašanja podataka, jer nam upravo mere disperzije omogućavaju da matematički definišemo šta predstavlja očekivanu varijaciju, a šta anomaliju koja narušava kvalitet celog modela.

Ključne mere disperzije podataka su:

- **Varijansa (*Variance*)** – aritmetička sredina kvadratnih odstupanja svakog pojedinačnog podatka od aritmetičke sredine celog skupa. Ona meri koliko su podaci raspršeni oko centra (srednje vrednosti), odnosno ukupnu količinu informacije u jednom atributu i ujedno je ključni indikator nestabilnosti podataka. Za N uzoraka, $x_1 \ x_2 \ ... \ x_N$, gde je x numerički atribut, a $\bar{x}$ srednja vrednost uzoraka, varijanse se računa formulom:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 \quad (4)$$

Pošto se u formuli koristi kvadrat odstupanja $(x_i - \bar{x})^2$, to znači da velika odstupanja (*outlier*-i) imaju eksponencijalno veći uticaj na krajnji rezultat.

- **Standardna devijacija (*Standard Deviation - STD*)** – kako se brojčana vrednost varijanse izražava u kvadratu merne jedinice atributa, kao češća mera disperzije koristi se standardna devijacija, koja nije ništa drugo nego kvadratni koren varijanse.

$$\sigma = \sqrt{\sigma^2} \quad (5)$$

Mala standardna devijacija ukazuje na to da su podaci tesno grupisani oko srednje vrednosti, dok velika vrednost ukazuje na to da su podaci široko raspršeni. Razmatranje ove mere je ključno za identifikaciju anomalija; na primer, kod podataka koji prate normalnu raspodelu, vrednosti koje odstupaju više od tri standardne devijacije od proseka obuhvataju svega 0.3% uzoraka i najčešće se tretiraju kao *outlier*-i. Detaljnija analiza ovog pravila i same normalne raspodele biće predmet **Poglavlja 3**. Pri tom, treba uzeti u obzir da se standardna devijacija koristi kao mera disperzije – samo ukoliko je i srednja vrednost prethodno uzeta kao centar podataka.

- **Opseg, kvantili i interkvartilni opseg (*Range, Quartiles, and Interquartile Range*)** – Opseg predstavlja razliku između najveće i najmanje vrednosti koju neki uzorak u skupu podataka ima za određeni atribut. On je zapravo još jedan od načina kako možemo da primetimo nepravilnosti u podacima, npr. **Range = 950** za kolonu godina starosti ispitanika. Kvantili su vrednosti koje dele uređeni skup podataka na podjednake delove. Najčešće korišćeni broj kvantila jeste četiri, gde su u tom slučaju svaki od delova naziva kvartil i predstavlja po 25% podataka. Ukoliko se podaci podele na sto kvantila, onda se svaki od njih naziva percenitl. Kvartili mogu poslužiti kao indikacija o centru (50ti percentil - medijan), rasponu i obliku distribucije. Interkvartilni opseg predstavlja razliku između trećeg i prvog kvartila, čime se meri raspršenost centralnih 50% podataka (25% od centra u oba smera). Jedinstvenost ove mere je njena potpuna otpornost na *outlier*-e, pa se s toga može koristiti za definisanje granica *outlier*-a kao:
 - **Donja granica:** $Q1 - 1.5 \cdot IQR$
 - **Gornja granica:** $Q3 + 1.5 \cdot IQR$ [1]


Poseban izazov u analizi varijanse predstavlja pojava **heteroskedastičnosti**. Dok homoskedastičnost podrazumeva da je varijansa greške (šuma) konstantna kroz ceo skup podataka, heteroskedastičnost se javlja kada se disperzija podataka menja u zavisnosti od vrednosti drugog atributa. U kontekstu kvaliteta podataka, ovo je kritičan problem jer ukazuje na to da pouzdanost naših merenja nije ujednačena. Na primer, ako analiziramo potrošnju domaćinstava, varijansa je često mnogo veća kod bogatijih porodica nego kod onih sa niskim primanjima. Prisustvo heteroskedastičnosti direktno narušava pretpostavke mnogih algoritama, poput linearne regresije, što dovodi do nepreciznih intervala poverenja i nepouzdatih predviđanja modela mašinskog učenja. Jedan od načina za merenje heteroskedastičnosti je Levinov test [3].

2.4 Momenti raspodele: Asimetrija (Skewness) i Spljoštenost (Kurtosis)

Nakon što smo definisali gde se podaci nalaze (centralna tendencija) i koliko su raspršeni (disperzija), poslednji korak u potpunoj statističkoj karakterizaciji je analiza oblika raspodele. Dok srednja vrednost i varijansa daju osnovne informacije, one ne mogu da opišu da li je raspodela simetrična ili su njeni repovi nagnuti na jednu stranu, niti da li je centar raspodele previše špicast ili zaravnjen. Za te potrebe koristimo momente višeg reda: **asimetriju (Skewness)** i **spljoštenost (Kurtosis)**. U dijagnostici kvaliteta podataka, ovi parametri su od ključnog značaja jer mnogi algoritmi mašinskog učenja, poput onih zasnovanih na pretpostavci normalnosti, gube na preciznosti ukoliko su podaci ekstremno asimetrični ili imaju teške repove (frekventne outliere). Razumevanje oblika raspodele omogućava nam da donesemo informisanu odluku o neophodnim transformacijama podataka, kao što su logaritamska ili Box-Cox transformacija, pre same faze treniranja modela.

Asimetrija može biti pozitivna (leva) – ukoliko se rep nalazi na desnoj strani (u smeru je prema pozitivnom delu x-ose); negativna (desna) – ukoliko se rep nalazi na levoj strani (u smeru je prema negativnom delu x-ose).

Spljoštenost ukazuje na sam oblik distribucije, odnosno na visinu (vrednost na y-osi) promenljive u odnosu na njenu širinu (vrednost na x-osi) [4]. Distribucija može biti leptokurtična (*leptokurtotic*) – špicasta, distribucija je previše visoka u odnosu na svoje repove i ima pozitivnu vrednost spljoštenosti; platikurtična (*platykurtotic*) – ravna i šira od normalne distribucije sa negativnom vrednošću spljoštenosti.




Slika 3. Grafičke predstave asimetričnosti i spljoštenosti [8]

3. ANALIZA RASPODELE I NORMALNOST PODATAKA

Analiza raspodele predstavlja ključni most između deskriptivne statistike i statističkog zaključivanja. Dok mere centralne tendencije i varijabiliteta opisuju 'šta' se u podacima dešava, analiza raspodele nam govori 'kako' su te vrednosti raspoređene u verovatnosnom prostoru. U srcu ove analize nalazi se normalna raspodela, koja u inženjerstvu podataka služi kao referentni model za kvalitet. Razumevanje prirode raspodele je od suštinske važnosti jer direktno diktira izbor analitičkih metoda: pogrešna pretpostavka o normalnosti može dovesti do primene neadekvatnih algoritama, što rezultira modelima koji su ili previše optimistični ili fundamentalno pogrešni. U ovom poglavlju fokus će biti na dijagnostičkim alatima koji omogućavaju istraživaču da utvrdi stepen usklađenosti realnih podataka sa teorijskim modelima, identifikujući pritom anomalije koje mogu narušiti integritet budućih predviđanja.

3.1 Značaj normalne raspodele za statističke algoritme

Normalna raspodela, poznata i kao Gausova raspodela (raspodela u obliku zvona), predstavlja temeljni koncept u analizi podataka, prvenstveno zbog svoje jedinstvene uloge u okviru parametarske statistike. Većina klasičnih statističkih algoritama i testova, kao što su **t-test** i **ANOVA**, zasnovana je na pretpostavci da podaci prate normalnu raspodelu. Sa druge strane nelinearni algoritmi nemaju ovu pretpostavku, ali obično daju bolje performanse pri ovakvoj raspodeli. Razlog za ovu dominaciju leži u predvidljivosti Gausove krive, gde su srednja vrednost, medijana i modus identični, a disperzija se strogo pokorava empirijskom pravilu 68.26%-95.44%-99.74%. Ove brojke su zapravo procentualne vrednosti u odnosu na jednu, dve ili tri standardne devijacije od centra. Dakle, kod normalne raspodele bi trebalo da 99.74% uzoraka bude tri standardne devijacije od centra, a sve ostalo statistički značajne ekstremne vrednosti. U kontekstu kvaliteta podataka, provera ove pretpostavke je kritična: ukoliko koristimo parametarske testove na podacima koji značajno odstupaju od normale, dobijeni rezultati (poput *p*-vrednosti i intervala poverenja) postaju nepouzdati. Stoga, analiza normalnosti nije samo formalni korak, već neophodan preduslov za validaciju svakog modela koji se oslanja na stabilnost parametara sredine i varijanse.



Slika 4. Grafik normalne distribucije [4]

Z-score služi za prevođenje bilo koje normalne raspodele u standardnu normalnu raspodelu (*mean* = 0 i $\sigma = 1$) i računa se preko formule:


$$z = \frac{x - \bar{x}}{\sigma} \quad (6)$$

T-test predstavlja inferencijalnu statističku tehniku namenjenu ispitivanju postojanja statistički značajne razlike između srednjih vrednosti dve nezavisne grupe. Ova metoda se najčešće koristi u situacijama kada je veličina uzorka relativno mala ($n < 30$) i tada je pretpostavka o normalnosti raspodele kritična za njenu validnost. Na osnovu izračunate t -statistike vrši se poređenje empirijskih rezultata sa nultom hipotezom (prema kojoj je razlika između srednjih vrednosti jednaka nuli), čime se procenjuje da li uočene razlike potiču od slučajnih varijacija ili od stvarnog efekta. Ukoliko je dobijena p -vrednost manja od 0.05, nulta hipoteza se odbacuje u korist alternativne. Dok je t -test ograničen na poređenje dve grupe, za analizu tri ili više grupa koristi se **ANOVA** (analiza varijanse), koja primenom F -testa upoređuje varijanse unutar grupa i između njih kako bi utvrdila stabilnost posmatranih parametara.

3.2 Vizuelne metode dijagnostike

Vizuelna dijagnostika služi kao preliminarna, ali nezaobilazna faza u analizi kvaliteta podataka. Umesto oslanjanja na jednu brojčanu vrednost, koristimo tri komplementarna grafička prikaza koji nam govore o centru, rasponu i obliku raspodele:

- **Histogram** - deli opseg vrednosti na intervale (*bins*) i prikazuje broj uzoraka koji upadaju u svaki interval. Na histogramu odmah vidimo asimetriju i spljoštenost, kao i samu distribuciju. Ako primetimo dva vrha (bimodalna raspodela), to nam signalizira da su podaci verovatno mešavina dva različita procesa (dva senzora) ili grupe (mužjaci i ženke životinje).
- **Box-plot** - kutijasti dijagram, zasnovan na kvartilima, fokusira se na robusnost podataka i može poslužiti kao dijagnostika ekstremnih vrednosti. Grafički prikazuje medijan i interkvartilni opseg unutar kutije, dok tačke koje se nalaze na vanjskim linijama („*brkovima*”) predstavljaju šumove i outliere.
- **Q-Q grafik (*Quantile-Quantile plot*)** – najprecizniji vizuelni alat koji direktno poredi empirijske kvantile odabranog uzorka sa kvartilima teoretske raspodele kao što je normalna ili eksponencijalna. Na grafiku postoji prava linija postavljena pod 45 stepeni i tačke koje čine odabrane podatke. Ukoliko tačke prate liniju – podaci su normalno distribuirani; ukoliko imaju zakrivljene krajeve (S-oblik) – podaci imaju više ekstremnih vrednosti od normalne distribucije (veća spljoštenost); ukoliko su zakrivljeni (u obliku luka) – podaci su asimetrični (jedan rep je znatno duži od drugog). Ako Q-Q grafik pokaže značajna odstupanja na krajevima, rezultati t -testa ili *ANOVA*-e postaju upitni, bez obzira na to šta kaže sam histogram.



Slika 5. Različite raspodele prikazane na Q-Q graficima [13]

3.3 Statistički testovi normalnosti

Iako vizuelne metode pružaju intuitivan i dragocen uvid u prirodu podataka, one uvek nose određenu dozu subjektivnosti — ono što jednom analitičaru na Q-Q plotu deluje kao prihvatljivo odstupanje, drugom može izgledati kao kritična anomalija. Da bi se donela konačna, matematički utemeljena odluka o (ne)ispunjenosti pretpostavke normalnosti, neophodno je primeniti formalne statističke testove. Ovi testovi funkcionišu unutar okvira testiranja hipoteza, gde nulta hipoteza (H_0) postavlja pretpostavku da uzorak potiče iz normalno raspoređene populacije. Rezultat testa, izražen kroz p-vrednost, daje nam egzaktn kriterijum za (ne)odbacivanje te pretpostavke. Pretpostavka se odbacuje (nisu normalni) ukoliko je $p < 0.05$, a ne odbacuje (normalni su) ukoliko je $p > 0.05$.

Tri najčešće korišćena testa:

- **Sharpiko-Wilk** – analizira posmatrane podatke kako bi se procenio stepen simetrije i spljoštenosti distribucije. Na osnovu poređenja sa normalnom raspodelom izračunava se p-vrednost, pri čemu se ona dobija iz zbira kvadrata uočenih odstupanja. Smatra se najmoćnijim testom za proveru normalnosti, naročito kod manjeg broja uzoraka. Osetljiv je na odstupanja od raspodele.
- **Kolmogorov-Smirnov (K-S)** - poredi posmatranu kumulativnu funkciju raspodele sa kumulativnom funkcijom normalne raspodele. P-vrednosti se dobija na osnovu oba odstupanja. Često se koristi kod velikih skupova podataka, ali je manje osetljiv od Sharpiko-Wilk-a.
- **D'Agostino-Pearson** – najpre računa asimetriju i spljoštenost posmatrane distribucije, a zatim je poredi sa normalnom distribucijom kako bi uvideo koliko one odstupaju i na osnovu zbira tih odstupanja izračunava p-vrednost. Ovim testom se može ustanoviti i razlog zašto podaci nisu normalno distribuirani.

Treba napomenuti da se opisani testovi normalnosti sprovede prvenstveno radi validacije uslova za primenu **parametarskih testova**. Međutim, sama normalnost nije dovoljna; za potpunu pouzdanost ovih metoda neophodno je potvrditi i heteroskedastičnost, kao i nezavisnost

opservacija (pojava jednog događaja ne utiče na verovatnoću pojave drugog događaja [3]). Ipak, u domenu mašinskog učenja, [3] ukazuje na to da rezultati algoritama često ne ispunjavaju ove stroge preduslove, čak i kada je veličina uzorka teoretski dovoljna. Bilo da se radi o stohastičkim algoritmima čiji rezultati variraju ili determinističkim metodama gde je uzorak ograničen, odstupanja od normalnosti su standarda pojava. U takvim scenarijima, profilisanje podataka nas direktno usmerava ka upotrebi **neparametarskih testova**, koji su znatno robusniji jer ne zavise od pretpostavki o obliku raspodele niti o homogenosti varijanse.

4. ANALIZA KORELACIJE I REDUNDANTNOSTI

Nakon detaljnog ispitivanja pojedinačnih karakteristika i raspodela svakog atributa, neophodno je analizirati njihove međusobne odnose. Kvalitet skupa podataka ne zavisi samo od preciznosti pojedinačnih merenja, već i od stepena zavisnosti i informativnosti čitavog sistema varijabli. Analiza korelacije omogućava nam da identifikujemo attribute koji dele slične obrasce ponašanja, dok analiza redundantnosti pomaže u prepoznavanju viška informacija koji može nepotrebno opteretiti modele mašinskog učenja ili dovesti do problema multikolinearnosti. Koristeći koncepte sličnosti i različitosti, cilj ovog poglavlja je da postavi okvir za selekciju najinformativnijih atributa i eliminaciju onih koji ne doprinose novom znanju o posmatranom fenomenu.

4.1 Mere sličnosti i različitosti podataka

Koncepti sličnosti i različitosti su fundamentalni u profilisanju podataka jer kvantifikuju koliko su dve jedinice posmatranja bliske jedna drugoj. Neformalno, prema [2] sličnost (s) je numerička mera koja je veća što su objekti sličniji (obično u opsegu $[0, 1]$, gde je 1 potpuna sličnost), dok je različitost (d) mera udaljenosti – što su objekti sličniji, udaljenost je manja. Za numeričke podatke, najčešće se koristi **Euklidska** udaljenost, dok se kod binarnih ili kategoričkih podataka primenjuju mere poput **Simple Matching Coefficient (SMC)** ili **Jaccard-ovog koeficijenta**. Razumevanje ovih mera omogućava nam da identifikujemo prirodne grupacije u podacima ili izolujemo objekte koji su toliko različiti od ostalih da se mogu smatrati anomalijama.

Minovski udaljenost:
$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}} \quad (7)$$

Gde je za $p = 2$ – Euklidska udaljenost, $p = 1$ – Menhentan udaljenost, a $p = \infty$ – Supremum. Upotrebljava se češće za podatke veće gustine (*dense*).

Cosinusna sličnost:
$$\cos(\theta) = \frac{x \cdot y}{\|x\| \|y\|} \quad (8)$$

Vrednost može biti u opsegu $[-1, 1]$ – gde 1 znači da vektori imaju maksimalnu sličnost. Češće se koristi kod podataka manje gustine (*sparse*).

Važno je napomenuti da je radi prilagođavanja specifičnim algoritmima često neophodno izvršiti **transformaciju samih mera bliskosti** (npr. prevođenje sličnosti u nesličnost) ili njihovo skaliranje na standardizovani interval $[0, 1]$, čime se osigurava da svi odnosi unutar skupa podataka budu matematički uporedivi i kompatibilni sa odabranim metodama analize. Za normalizovane podatke, prevođenje je jednostavno poput:

$$d = 1 - s \quad (9)$$

Na osnovu ovoga može se zaključiti da je uzorak, čija je udaljenost d od ostalih uzoraka prevelika (sličnost s je premala), zapravo *outlier*.


4.2 Koeficijenti korelacije

Dok mere sličnosti iz prethodnog poglavlja porede uzorke (redove), koeficijenti korelacije mere **povezanost između atributa (kolona)**¹. Za numeričke vrednosti najpopularniji koeficijenti su:

- **Pirsonov koeficijent korelacije (r)** - meri jačinu i smer linearne povezanosti između dve kontinualne varijable:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (10)$$

Gde su n – broj uzoraka, x_i i y_i – i -ti uzorci, $\bar{x}$ i $\bar{y}$ – srednje vrednosti uzoraka. Generalizovanije, brojilac formule predstavlja kovarijansu (biće reči u kasnijem delu rada) uzoraka, a imenilac standardne devijacije uzoraka. Vrednost r može biti u opsegu $[-1,1]$, gde 1 označava savršenu pozitivnu linearnu vezu, -1 savršenu negativnu, dok 0 ukazuje na nepostojanje linearne veze. Pozitivna korelacija znači da kada se povećava vrednost x , povećava se i y ; Negativna korelacija znači da se povećanjem jedne vrednosti, smanjuje druga vrednost. Mana ove mere je njena osetljivost na *outlier*-e i preduslov normalne distribucije podataka. U suprotnom, dobijena vrednost može biti lažni prikaz korelacije.



Slika 6. Prikaz nekoliko skupova tačaka (x,y) i vrednosti koeficijenta korelacije između x i y . Prvi red: jačina i smer linearnog odnosa; Drugi red: nagib odnosa; Treći red: vrednost pri nelinearnim slučajevima. [14]

- **Spirmanov koeficijent korelacije rangova (ρ)** – neparametarska alternativa za merenje monotone korelacije koja ne koristi direktne vrednosti podataka, već njihove rangove (poziciju u sortiranoj listi), zbog čega je mnogo robusniji na ekstremne vrednosti. Vrednost koeficijenta može biti u istom opsegu kao i Pirsonov, ali je razlika u tome što na primer, ukoliko vrednost x raste, vrednost y ne mora da raste linearno, već može recimo eksponencijalno.
- **Chi-square (χ^2) test** – koristi se za kategoričke podatke, tako što poredi uočene frekvencije (o) sa očekivanim frekvencijama (e) koje bi postojale da su varijable potpuno nezavisne. Najpre se formira tabela kontingencije [3] (koliko se često dva atributa, recimo A i B, pojavljuju zajedno), gde svako polje predstavlja uočenu frekvenciju (o_{ij}) zajedničkog pojavljivanja vrednosti a_i i b_j . Očekivane frekvencije (e_{ij}) se izračunavaju kao:

¹ Ne mora uvek da znači – korelacija se može koristiti i za poređenje para uzoraka, ali se u praksi, zbog različitih tipova atributa i skala merenja pojedinačnih skupova, to ređe čini. [2]

$$e_{ij} = \frac{\text{count}(A = a_i) \times \text{count}(B = b_j)}{m} \quad (11)$$

Gde je m broj uzoraka u skupu podataka, $\text{count}(A = a_i)$ broj uzoraka koji imaju vrednost a_i za atribut A i $\text{count}(B = b_j)$ broj uzoraka koji imaju vrednost b_j za atribut B.

Na osnovu ovoga, χ^2 se može izračunati kao:

$$\chi^2 = \sum_{i=1}^c \sum_{j=1}^r \frac{(o_{ij} - e_{ij})^2}{e_{ij}} \quad (12)$$

Gde su c i r broj različitih kategorija koje se sadrže u atributima A i B.

Poredeći dobijeni rezultat (uzimajući u obzir broj stepena slobode) sa teorijskom raspodelom, na osnovu dobijenog nivoa značajnosti (p -vrednost), može se odrediti da li si atributi A i B statistički povezani i redundantni.

Kao alternativu korelacionim merama, koristi se izuzetno popularna mera sličnosti koja nije prethodno spomenuta² – **Uzajamna informacija (Mutual Information)**. Zasnovana na entropiji, potiče iz teorije informacija i pokazuje koliko informacija o jednoj varijabli dobijamo posmatranjem druge varijable. Jačina ove mere se nalazi u tome što nije ograničena ni tipom raspodele ni prirodom odnosa. Normalizovani opseg vrednosti je $[0,1]$ gde 0 označava da su varijable potpuno nezavisne, a što je vrednost veća, to je jača zavisnost, bez obzira na to da li je ona linearna, nelinearna ili potpuno neregularna. Ova vrednost se u praksi obično prikazuje matricom korelacije svih atributa u skupu podataka.

4.3 Redundantni atributi i multikolinearnost

U procesu profilisanja podataka, visoka korelacija između atributa često se pogrešno interpretira kao pozitivan znak, dok ona zapravo može ukazivati na ozbiljan problem **redundantnosti**. Atribut je redundantan ukoliko ne pruža nikakvu novu informaciju u odnosu na skup već postojećih atributa, što se najčešće dešava kada su dve varijable direktno povezane (npr. cena sa i bez poreza) ili kada jedna varijabla predstavlja linearnu kombinaciju drugih. Neko ustaljeno pravilo kaže da uzajamna korelacija sa vrednošću > 0.9 , predstavlja redundantnost između atributa, pa se jedan od njih može izbaciti. Naravno, ukoliko se racionalno može zaključiti da ti atributi nemaju logičke povezanosti (npr. geografska lokacija i fizička karakteristika tela), onda nema potrebe za izbacivanjem jednog od njih, jer to nisu redundantni atributi, već jasni separatori. Poseban i kompleksniji oblik ovog problema je **multikolinearnost** — pojava gde jedna nezavisna varijabla može biti sa visokom preciznošću predviđena pomoću više drugih varijabli istovremeno. Prisustvo ovakvih atributa ne samo da nepotrebno povećava dimenzionalnost prostora i usporava procesiranje, već može dovesti do matematičke nestabilnosti modela i otežati interpretaciju važnosti pojedinačnih parametara. Jedna od mera multikolinearnosti jeste **VIF (Variance Inflation Factor)** koji meri koliko je jedan atribut povezan sa svim ostalim atributima istovremeno. VIF se

² Ovdje bih hteo da istaknem razliku između dva termina: dok korelacija označava praćenje kretanja uzajamnih podataka, odnosno kako se oni zajedno menjaju, sličnost označava meru blizine podataka u višedimenzionalnom prostoru.

izračunava za svaki atribut pojedinačno tako što se taj atribut postavi kao zavisna varijabla u regresionom modelu, dok svi ostali atributi služe kao prediktori:

$$VIF_i = \frac{1}{1 - R_i^2} \quad (13)$$

Gde je R_i^2 koeficijent determinacije regresionog modela za i -ti atribut koji govori koliki procenat varijanse tog atributa se može objasniti pomoću ostalih varijabli u skupu. Za vrednost $VIF = 1$ – nema korelacije između odabranog atributa i ostalih (on pruža potpuno jedinstvenu informaciju); za $1 < VIF < 5$ – postoji umerena korelacija, ali ona obično nije kritična za stabilnost modela; za $VIF > 5$ – ukazuje na potencijalno visoku (problematičnu) multikolinearnost; $VIF > 10$ – ukazuje na ozbiljno visoku multikolinearnost [15]. Visok VIF ukazuje na to da se informacija koju nosi jedan atribut već nalazi 'distribuirana' kroz druge attribute, što ga čini kandidatom za uklanjanje. Eliminacijom atributa sa visokim VIF-om smanjujemo kompleksnost modela bez značajnog gubitka informacija, čime direktno poboljšavamo kvalitet skupa podataka.

4.4 Kovarijansa i međuzavisnost varijabli

Da bi se zaokružila priča o korelaciji, neophodno je definisati njenu osnovu – **kovarijansu**. Dok se korelacije koriste kao standardizovane mere, kovarijansa nam daje uvid u samu srž linearnog odnosa. Ona je statistička mera koja pokazuje u kojoj meri se dve varijable menjaju zajedno. Ako obe varijable imaju tendenciju da rastu istovremeno, kovarijansa je pozitivna; ako jedna raste dok druga opada, kovarijansa je negativna. Glavna razlika u odnosu na korelaciju je u tome što kovarijansa zavisi od mernih jedinica atributa. Na primer, kovarijansa između visine u metrima i težine biće bročano drugačija nego ako visinu izrazimo u milimetrima. Upravo zato, korelacija (Pirsonov koeficijent) se definiše kao normalizovana kovarijansa (13).

Iako je korelacija pogodnija za interpretaciju zbog svoje standardizacije, kovarijansa je nezaobilazna u metodama poput **Analize glavnih komponenti (PCA)** i **Mahalanobisove udaljenosti**. Ona zadržava informaciju o varijabilitetu (skali) podataka, što omogućava algoritmima da prepoznaju koji atributi nose najveći intenzitet informacije unutar sistema.

5. DETEKCIJA ANOMALIJA KAO INDIKATOR KVALITETA


Detekcija anomalija predstavlja jedan od najvažnijih aspekata profilisanja podataka, jer direktno ukazuje na potencijalne probleme u kvalitetu, integritetu ili samom procesu generisanja informacija. U svakom skupu podataka koji potiče iz realnih sistema, neminovno je prisustvo vrednosti koje odstupaju od očekivanih obrazaca. Identifikacija ovih odstupanja nije samo tehnički korak ka 'čišćenju' podataka, već suštinski dijagnostički proces: ona nam pomaže da razumemo da li su te vrednosti rezultat slučajnih grešaka u merenju, sistemskih kvara senzora ili pak predstavljaju retke, ali legitimne događaje koji nose najveću informativnu vrednost. Anomalije se najuobičajnije predstavljaju u vidu šumova, ekstremnih vrednosti (*outlier-a*), nedostajućih vrednosti, artifakta, pristusnosti uzoraka stranih distribucija, nekonzistentnih podataka, itd. Svaka od ovih anomalija ujedno predstavlja posebnu i široku temu istraživanja, te će se rad dotaći samo najosnovnijih principa definisanja i detekcije pojmova, kao i samog uticaja na kvalitet podataka.

5.1 Taksonomija anomalija: Šum (*Noise*) i Ekstremne vrednosti (*Outliers*)

Iako se u širem kontekstu oba termina odnose na podatke koji odstupaju od normale, njihovo porijeklo i tretman u profilisanju su fundamentalno različiti. **Šum** predstavlja nasumičnu komponentu greške merenja [2]. On je najčešće nusproizvod nesavršenosti mernih instrumenata, problema pri prenosu podataka ili ljudskog faktora i po definiciji je nepoželjan jer nema nikakve analitičke vrednosti. Međutim, dok se šum filtrira, **outlier-i** se detaljno istražuju jer mogu otkriti nove obrasce ili kritične greške u sistemu koje nisu slučajne.

Najjednostavnije rečeno, *outlier* je uzorak koji se značajno razlikuje po vrednosti(ma) od ostalih uzoraka u skupu podataka. Ukoliko nam je poznata distribucija podataka (bilo koja od teorijskih distribucija, npr. Gausova), *outlier*-e možemo definisati i kao one uzorke koji ne prate datu distribuciju (distribuciju većine podataka). Kao što je ranije pominjano u 3.1, za slučaj normalne distribucije, sve vrednosti preko ± 3 standardne devijacije, se smatraju *outlier*-ima. Još jedan tip ekstremnih vrednosti mogu biti i takozvani ***fringelier-i*** – uzorci koji se nalaze na ivicama normalne raspodele (oko $\pm 3 \sigma$) i za koje je malo verovatno da pripadaju populaciji od interesa, no ipak u maloj meri pripadaju [4].

Iako ne postoje ustanovljene podele, mogu postojati: šum klase i šum atributa [3], a neki od filtera šuma jesu *Ensemble Filter*, *Cross-Validated Committees Filter*, *Iterative-Partitioning Filter*... [3]; globalni *outlier*-i, kontekstualni (uslovni) *outlier*-i i kolektivni *outlier*-i [1]³.




Slika 7. Skater prikaz outlier-a kod Normalne distribucije [1] / Outlier-i i Fringelier-i kod normalne distribucije [4]

³ Ovo su samo neke podele koje se nalaze u priloženim literaturama, a koje sam smatrao adekvatnim.

5.2 Statistički pristupi detekciji outlier-a

Metodi detekcije outlier-a razlikuju se po svojoj primeni u odnosu na sam skup podataka koji nadgledamo, a zavisno od matematičkog pristupa koji se koristi mogu se klasifikovati na⁴:

- **Statistički pristupi (*Statistics-based*)** – zasnivaju se na testiranju statističkih hipoteza i uklapanju podataka u određene teorijske distribucije. Dele se na parametarske (pretpostavljaju unapred poznatu raspodelu, poput Gausove) i neparametarske metode (npr. *Kernel* funkcije koje ne pretpostavljaju fiksnu formu raspodele).
- **Pristupi zasnovani na udaljenosti (*Distance-based*)** – identifikuju anomalije na osnovu njihove udaljenosti od najbližih suseda ili gustine naseljenosti prostora oko njih. Razlikujemo globalne i lokalne pristupe, kao i metode zasnovane na udaljenosti (*distance-based*) naspram onih zasnovanih na gustini (*density-based*, npr. *LOF* algoritam).
- **Pristupi zasnovani na modelima (*Model-based*)** – koriste tehnike mašinskog učenja kako bi izgradili model normalnog ponašanja. Ovi modeli mogu pretpostavljati jednu klasu normalnosti (npr. One-Class SVM) ili više klasa normalnih stanja.



Kao prirodni i logični nastavak procesa profilisanja podataka opisanog u prethodnim poglavljima, rad će se fokusirati isključivo na statističkom pristupu koji direktno koristi parametre distribucije i odnos između atributa kako bi se dobili transparentni i lako interpretabilni indikatori kvaliteta. Za razliku od kompleksnijih modela mašinskog učenja koji često funkcionišu kao crna kutija (*black box*), statistički metodi poput **Z-score-a** i **Mahalanobisove** udaljenosti omogućavaju precizno razumevanje zašto je određeni podatak proglašen anomalijom na osnovu same matematičke strukture skupa podataka.

- **Z-score** - kao što je ranije pomenuto u 3.1, predstavlja broj standardnih devijacija za koji određeni uzorak odstupa od aritmetičke sredine i računa se formulom (6). U procesu profilisanja kvaliteta podataka, ova metoda se koristi za brzu identifikaciju ekstremnih vrednosti unutar pojedinačnih atributa.
- **Mahalanobisova udaljenost (D_M)** - analizira uzorak u odnosu na čitav višedimenzionalni prostor, uzimajući u obzir kovarijansu između atributa. Ona praktično predstavlja Z-score u više dimenzija i računa se:

$$D_M(x) = \sqrt{(x - \mu)^T \left(\sum (x - \mu) \right)^{-1}} \quad (14)$$

Ukoliko je dobijena vrednost visoka – verovatno je u pitanju outlier. Preporučljivija je od Z-score-a ili Euklidijanske udaljenosti kada su atributi korelisani.

⁴ Osnova ovakve podele je izvučena iz [6], za širu podelu može se upotrebiti [1].

5.3 Uticaj ekstremnih vrednosti na mere varijanse i korelacije

Prisustvo ekstremnih vrednosti u skupu podataka može izazvati ozbiljne devijacije u statističkim analizama, često dovodeći do pogrešnih interpretacija kvaliteta podataka tako što direktno povećavaju varijansu greške (*unexplained variance*) i smanjuju snagu statističkih testova menjajući asimetriju (*skewness*) i spljoštenost (*kurtosis*) varijabli.

5.3.1 Uticaj na korelaciju i regresiju

Outlieri imaju disproporcionalno veliki uticaj na Pearsonov koeficijent korelacije koji se zasniva na sumiranju kvadrata odstupanja od srednje vrednosti – jedna jedina ekstremna tačka može stvoriti korelaciju tamo gde ona ne postoji ili je dramatično srušiti u skupu gde je veza inače snažna. U regresionoj analizi, ekstremne vrednosti deluju kao "tačke oslonca" koje povlače regresionu liniju ka sebi, čime model postaje pristrasan (*biased*) i gubi sposobnost generalizacije na nove podatke.

5.3.2 Uticaj na t-test i ANOVA

Kao što je prethodno opisano u 3.2, ovi testovi porede varijansu između grupa sa varijansom unutar grupa (greškom). Kako *outlier*-i drastično povećavaju varijansu unutar grupe, oni maskiraju stvarne razlike između srednjih vrednosti. To direktno vodi ka **grešci tipa II** – nemogućnosti da se pronađe statistički značajan rezultat koji zapravo postoji, samo zato što je varijansa greške prevelika.

5.3.3 Uticaj na procenu parametara

Srednja vrednost i standardna devijacija su ekstremno osetljive na *outlier*-e. Jedna ekstremna vrednost može pomeriti prosek skupa do tačke koja više uopšte ne reprezentuje tipičan uzorak, čineći profilisanje podataka neadekvatnim. Najpoznatiji primer je promena prosečne plate u sobi kada u nju uđe *Bill Gates* [16].

6. PREPORUKE ZA POBOLJŠANJE KVALITETA

Nakon sprovedenog procesa profilisanja, koji obuhvata detaljnu analizu distribucija, identifikaciju korelacionih zavisnosti i detekciju anomalija, krajnji korak u inženjerstvu podataka je definisanje konkretnih mera za optimizaciju skupa podataka. Rezultati profilisanja ne služe samo kao statični izveštaj o kvalitetu, već kao putokaz za primenu adekvatnih transformacija i strategija čišćenja. Poboljšanje kvaliteta podataka u ovoj fazi podrazumeva prelazak sa sirovih, često nekonzistentnih i asimetričnih podataka, na strukturu koja je matematički stabilnija i prilagođena pretpostavkama algoritama koji će se koristiti u fazi modelovanja.

6.1 Identifikacija potrebe za transformacijom podataka

Transformacija podataka se primenjuje kada rezultati profilisanja ukazuju na značajna odstupanja od pretpostavki koje zahtevaju algoritmi mašinskog učenja ili statistički testovi. Najčešći indikatori za transformaciju su visoka asimetrija (*skewness*), heteroskedastičnost (nejednaka varijansa) i nelinearni odnosi između varijabli.

- **Logaritamska transformacija** – koristi za rešavanje problema pozitivne asimetrije (*Skewness* > 1). Logaritmovanje sabija visoke vrednosti i rasteže niske, čime se distribucija približava normalnoj. Primenjuje se samo nad strogo pozitivnim vrednostima i predstavlja poseban slučaj stepene transformacije.
- **Box-Cox** – familija transformacija definisana parametrom λ . Ona je sofisticiranija od logaritamske jer automatski traži optimalni parametar koji će podatke najviše približiti normalnoj raspodeli, a primenjuje se kada logaritamska transformacija ne daje zadovoljavajuće rezultate ili kada želimo automatizovan proces stabilizacije varijanse. Ukoliko testovi normalnosti (poput *Shapiro-Wilk* testa iz 3.3) pokažu značajno odstupanje ($p < 0.05$), *Box-Cox* se koristi kao univerzalno sredstvo za postizanje normalnosti:

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln(y), & \lambda = 0 \end{cases} \quad (15)$$

Gde je $y^{(\lambda)}$ transformisana varijabla, a λ parametar transformacije. Takođe se primenjuje nad strogo pozitivnim vrednostima, ali u slučaju da imamo i negativne vrednosti – možemo dodati parametar koji će predstavljati *offset*. Vrednost λ se nalazi iterativno, testiranjem različitih vrednosti sa malim pomerajem u opsegu [-3,3] [3].

6.2 Strategije za tretiranje identifikovanog šuma i anomalija

Detektovanjem anomalija nekim od metoda opisanim u poglavlju 5, neophodno je primeniti adekvatnu strategiju njihovog tretiranja. Pogrešna odluka u ovom koraku može dovesti do gubitka dragocenih informacija ili, s druge strane, do ostavljanja šuma koji će kompromitovati buduće modele. Najčešće primenjivane odluke jesu uklanjanje (npr. nelogičnost vrednosti uzorka u odnosu na domen atributa), *winsorizing* (zamena vrednosti *outlier*-a u graničnu) i imputacija (npr. zamena vrednosti šuma ili nedostajućih vrednosti).

7. AUTOMATSKO MAŠINSKO UČENJE (AutoML)

Dok prethodna poglavlja detaljno opisuju manuelne i polu-automatizovane metode profilisanja koje zahtevaju visok stepen inženjerske ekspertize, savremeni razvoj discipline donosi koncept automatizovanog mašinskog učenja (*AutoML*). *AutoML* teži da automatizuje celokupan životni ciklus razvoja modela, sa posebnim fokusom na fazu predobrade podataka koja je često najzahtevniji deo posla. Umesto da inženjer ručno identifikuje potrebu za *Box-Cox* transformacijom ili bira strategiju za tretiranje outliera, *AutoML* sistemi koriste algoritamsku optimizaciju kako bi samostalno testirali različite cevovode (*pipelines*) transformacija i odabrali onaj koji maksimizuje performanse modela. Međutim, iako ovi sistemi dramatično ubrzavaju proces, oni ne eliminišu potrebu za razumevanjem unutrašnje strukture podataka; naprotiv, profilisanje opisano u ovom radu ostaje ključni kontrolni mehanizam koji osigurava da automatizovani procesi ne postanu crne kutije (*black boxes*) koje donose matematički optimalne, ali logički neodržive odluke.

7.1. Koncept automatizacije profilisanja

Koncept automatizacije profilisanja zasniva se na prebacivanju uloge analitičara na algoritamske sisteme koji su sposobni da u realnom vremenu vrše meta-analizu skupa podataka. Umesto statičnog posmatranja histograma ili ručnog izračunavanja korelacionih matrica, automatizovano profilisanje koristi heuristike i statističke testove (poput *Shapiro-Wilk* testa za normalnost ili *VIF* faktora za kolinearnost) kao ulazne parametre za donošenje odluka. Ovaj proces započinje automatskom detekcijom tipova podataka (semantičko tipiziranje), nakon čega sistem primenjuje set pravila za identifikaciju narušenog integriteta, kao što su nedostajuće vrednosti ili distribucije sa visokim stepenom asimetrije. Ključni doprinos automatizacije leži u mogućnosti da se profilišu masovni podaci (*Big Data*) gde manuelna inspekcija nije fizički moguća, pri čemu se generišu dinamički izveštaji koji automatski rangiraju varijable po njihovoj prediktivnoj snazi i stepenu šuma, čime se faza 'upoznavanja sa podacima' skraćuje sa nekoliko dana na nekoliko minuta.

7.2. AutoML alati i tehnike predobrade

U praksi se koncept automatizacije realizuje kroz specifične *AutoML* okvire koji predobradu podataka ne posmatraju kao izolovan korak, već kao integralni deo optimizacionog problema. Ovi alati koriste različite strategije za rešavanje problema kvaliteta podataka:

- ***Auto-sklearn***: Ovaj sistem koristi 14 metoda za predobradu karakteristika (kao što su *PCA*, *Kernel PCA* i *ICA*) i 4 metode za direktnu predobradu podataka, uključujući automatsku imputaciju (*imputation*), balansiranje klasa (*balancing*) i skaliranje (*rescaling*). Specifičnost *Auto-sklearn-a* je korišćenje meta-učenja (*meta-learning*), gde sistem na osnovu meta-karakteristika novog skupa podataka prepoznaje koje su strategije čišćenja bile uspešne na sličnim problemima u prošlosti.
- ***TPOT (Tree-based Pipeline Optimization Tool)***: Za razliku od fiksnih sekvenci, *TPOT* koristi genetsko programiranje kako bi autonomno izgradio i optimizovao cevovode (*pipelines*) koji se sastoje od serije predprocesora karakteristika i modela mašinskog učenja. Cilj je pronalaženje najefikasnije kombinacije transformacija bez ikakvog unosa od strane korisnika.
- ***Hyperopt-Sklearn* i *Auto-WEKA***: Ovi rani sistemi uveli su pristup gde se izbor klasifikatora i izbor modula za predobradu tretiraju kao jedan veliki, zajednički hiperparametarski prostor (*CASH* problem). Na taj način, sistem može otkriti da određeni

model (npr. *SVM*) najbolje funkcioniše uz specifičnu transformaciju koju inženjer možda ne bi manuelno odabrao.

- ***The Automatic Statistician***: Ovaj sistem ide korak dalje ka interpretabilnosti, generišući izveštaje na prirodnom jeziku koji objašnjavaju korake predobrade i modeliranja, čime se premošćuje jaz između crne kutije i potrebe za razumevanjem odluka donetih tokom čišćenja podataka [17].

7.3. Industrijska rešenja: Cloud AutoML platforme

U industrijskom okruženju, procesi profilisanja i predobrade podataka postali su deo integrisanih cloud platformi koje omogućavaju skalabilnost na ogromnim skupovima podataka (*Big Data*). Najznačajniji predstavnici ovih rešenja koriste napredne pristupe za automatizaciju podataka:

- ***Google Cloud Vertex AI (AutoML)***: Google koristi tehnologiju koja se oslanja na duboko učenje ne samo za modele, već i za analizu strukture podataka. *Vertex AI* automatski prepoznaje tipove podataka i primenjuje sofisticirane transformacije kao što je *target encoding* za kategoričke varijable i automatsko skaliranje. Posebno je značajan njihov *Feature Store* koji omogućava da se profilisane i očišćene karakteristike ponovo koriste u različitim projektima, čuvajući integritet podataka na nivou cele organizacije.
- ***Microsoft Azure AutoML***: *Azure* se ističe po svom *Data Guardrails* sistemu. Dok sistem vrši automatizovanu predobradu (poput tretiranja asimetrije), on istovremeno generiše izveštaje o rizicima. Na primer, *Azure* će automatski upozoriti inženjera ako detektuje preveliku asimetriju, preveliki broj nedostajućih vrednosti ili debalans klasa, delujući kao automatizovani statistički savetnik.
- ***Amazon SageMaker Autopilot***: Amazonov pristup je specifičan po svojoj transparentnosti. Iako je proces automatizovan, *Autopilot* generiše čitave sveske (*notebooks*) sa *Python* kodom koji tačno prikazuje kako su podaci profilisani, koji su outlieri uklonjeni i koja je strategija transformacije primenjena. Ovo omogućava inženjerima da zadrže kontrolu i *audit* nad procesom čišćenja, što je ključno za visoko regulisane industrije poput finansija ili medicine.

8. ZAKLJUČAK

Profilisanje podataka predstavlja fundamentalni proces koji sirove informacije transformiše u pouzdan temelj za donošenje odluka i izgradnju stabilnih analitičkih modela. Kvalitet podataka nije apsolutna kategorija, već rezultat precizne dijagnostike unutrašnjih struktura skupa podataka. Analizom distribucija, utvrđivanjem normalnosti i identifikacijom asimetrije, postavljaju se okviri u kojima statistički testovi zadržavaju svoju validnost. Dalje, razumevanjem korelacija i multikolinearnosti kroz *VIF* faktor, sprečava se redundansa koja bi mogla da ugrozi efikasnost modela, dok se primenom multivarijantnih metoda poput Mahalanobisove distance omogućava detekcija anomalija koje ostaju nevidljive pri standardnim univarijantnim analizama. Konačno, zaključuje se da profilisanje nije samo tehnička priprema, već proaktivna inženjerska disciplina: prepoznavanje potrebe za transformacijama poput *Box-Cox*-a ili adekvatnog tretmana outliera direktno sprečava greške tipa II i osigurava da zaključci izvedeni iz podataka budu generalizabilni i ponovljivi. U eri u kojoj dominira kvantitet informacija, sposobnost dubinskog profilisanja postaje ključni separator između algoritama koji daju površne rezultate i onih koji generišu stvarnu vrednost zasnovanu na integritetu podataka.

Kroz rad je najpre **identifikovan problem** uticaja podataka na modele – loš kvalitet podataka (šum, outlieri, asimetrija) direktno narušava pretpostavke algoritama; **dati su načini** same identifikacije problema – vizuelizacijom (*Q-Q plot*, histogrami) i statističkim testovima (npr. *Shapiro-Wilk*); **predložena su moguća rešenja** ocene kvaliteta – analizom distribucije (asimetrija i spoljoštenost), analizom korelacije (npr. *Pearson*) i statističkim profilisanjem (mere centralne tendencije i disperzije); **odgovoreno je pod kojim uslovima** se ta rešenja primenjuju - zavisno od tipa podataka (numerički i linearni - *Pearson*), od veličine uzoraka (manji uzorci – *Shapiro-Wilk*, veći uzorci – *Kolmogorov-Smirnov*) i od broja *outlier*-a; rešenja se **zasnivavaju** na matematičkoj teoriji – teorija verovatnoće, linearna algebr, itd; **ustanovljene su** dobre i loše strane primene rešenja – dobre: matematički dokaz kvaliteta, loše - može se izgubiti originalno značenje vrednosti koje predstavljaju transformisane karakteristike (kako objasniti logaritam nečega nekome ko ne zna šta je logaritam), pojedini rezultati nisu uvek reprezentativni jer ne rade najbolje ako nisu recimo normalno distribuirani (*Z-score*).

LITERATURA

- [1] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Waltham, MA: Morgan Kaufmann, 2011.
- [2] P.-N. Tan, M. Steinbach, A. Karpatne, and V. Kumar, *Introduction to Data Mining*, 2nd ed. Noida, India: Pearson, 2019.
- [3] S. García, J. Luengo, and F. Herrera, *Data Preprocessing in Data Mining*, vol. 72. Cham, Switzerland: Springer International Publishing, 2015. doi: 10.1007/978-3-319-10247-4.
- [4] J. W. Osborne, *Best Practices in Data Cleaning: A Complete Guide to Everything You Need to Do Before and After Collecting Your Data*. Thousand Oaks, CA: SAGE Publications, Inc., 2013. doi: 10.4135/9781452269947.
- [5] J. Brownlee, *Data Preparation for Machine Learning: Data Cleaning, Feature Selection, and Data Transforms in Python*. Machine Learning Mastery, 2020.
- [6] I. F. Ilyas and X. Chu, *Data Cleaning*. New York, NY: Association for Computing Machinery, 2019. doi: 10.1145/3310205.
- [7] <https://dilipkumar.medium.com/mahalanobis-distance-usage-in-machine-learning-2bd4bcacbcd2>
- [8] <https://pub.aimind.so/understanding-kurtosis-exploring-the-shape-of-data-distribution-and-interpreting-q-q-plots-2d264fa2aa79>
- [9] <https://www.ibm.com/think/topics/data-quality>
- [10] <https://www.gartner.com/en>
- [11] <https://shelf.io/blog/garbage-in-garbage-out-ai-implementation/>
- [12] <https://www.geeksforgeeks.org/maths/difference-between-mean-median-and-mode-with-examples/>
- [13] <https://medium.com/aiskunks/crash-course-in-data-seeing-is-believing-exploring-data-distributions-with-q-q-plots-803992fae0da>
- [14] https://en.wikipedia.org/wiki/Pearson_correlation_coefficient
- [15] <https://medium.com/@ajayverma23/understanding-vif-what-it-is-and-why-its-needed-c24125b5c73f>
- [16] <https://curbal.com/the-bill-gates-effect-in-google-analytics-and-how-to-get-rid-of-it-with-power-bi>
- [17] F. Hutter, L. Kotthoff, and J. Vanschoren, Eds., *Automated Machine Learning: Methods, Systems, Challenges*. Cham, Switzerland: Springer Nature Switzerland AG, 2019. doi: 10.1007/978-3-030-05318-5.