

UNIVERZITET U NIŠU
ELEKTRONSKI FAKULTET



Vedran Mitić 2123

SEMINARSKI RAD

Inžinjeriing kvaliteta podataka za obučavanje generativnih Decoder-only transformera

Mentor:

prof. dr Aleksandar Stanimirović

2026.

Sadržaj

1. Uvod.....	3
2. Arhitektura <i>Decoder-only</i> modela i zavisnost od podataka.....	4
2.1. Princip rada: <i>Next-token</i> prediction i uticaj strukture podataka.....	4
2.2. Pre-training (kvantitet) vs. Fine-tuning (kvalitet).....	5
2.3. Aktuelni modeli i izvori njihovih podataka	5
3. Dimenzije kvaliteta tekstualnih podataka	7
3.1. Leksički parametri	7
3.2. Šum u masovnim podacima	8
3.3. Kontaminacija podataka.....	9
3.4. Algoritamska detekcija preklapanja: <i>MinHash</i> i <i>LSH</i>	10
4. Tehnike preobrade i normalizacije.....	11
4.1. Moderni tokenizatori.....	11
4.2. Deduplikacija	11
4.2.1. Repetition Loop	12
4.2.2. Memorizacija i generalizacija	12
4.2.3. Jaccard-ov indeks sličnosti	12
4.3. Jezička identifikacija.....	13
5. Kuracija podataka i poravnanje (Alignment).....	15
5.1. Heurističko filtriranje: Lingvistička pravila i bezbednost	15
5.2. Filtriranje zasnovano na modelu.....	16
5.3. <i>SFT</i> i <i>RLHF</i>	17
6. Uloga semantičkih modela u modernoj predobradi	18
6.1. LLM-as-a-Judge.....	18
7. Evolucija ka sintetičkoj predobradi: Generisanje i destilacija znanja	20
7.1. Destilacija podataka (<i>Data Distillation</i>) i Teacher-Student dinamika	20
7.2. Samoispravljanje (<i>Self-Correction</i>) i automatizovano rezonovanje	20
7.3. Dinamičko učenje po planu (<i>Curriculum Learning</i>)	20
7.4. Rizik od urušavanja modela (<i>Model Collapse</i>).....	21
8. Zaključak.....	22
LITERATURA.....	23

1. Uvod

U savremenoj eri veštačke inteligencije, dominacija **Decoder-only** transformatorskih arhitektura, predvođenih modelima iz *GPT* i *Llama* serija, iz korena je promenila pristup obradi prirodnih jezika (*NLP*). Dok su rani istraživački napor bili primarno fokusirani na povećanje broja parametara i računarske moći, poslednji trendovi u razvoju **velikih jezičkih modela (LLM)** nedvosmisleno ukazuju na to da je kvalitet podataka postao kritičniji faktor od same veličine modela. Nalazi o optimalnom odnosu veličine modela i količine podataka (*scaling laws*) ukazali su da dostupnost visokokvalitetnih podataka postaje primarno ograničenje daljeg napretka.


Ovaj rad analizira kompleksan put transformacije sirovog, bučnog teksta sa interneta u visokokvalitetne korpusne pogodne za obučavanje generativnih modela. Fokusirajući se na specifičnosti *Decoder-only* arhitektura, istraživanje obuhvata klasične pojmove kvaliteta poput leksičkog diverziteta i šuma, ali ih proširuje na savremene izazove kao što su deduplikacija na nivou dokumenata, semantičko filtriranje i tokenizacija podreči. Kroz teorijsku analizu, rad nastoji da identifikuje kako adekvatna predobrada direktno utiče na smanjenje halucinacija i povećanje činjenične tačnosti modela, postavljajući temelje za razvoj robusnijih i pouzdanijih sistema veštačke inteligencije.

Ova zavisnost od podataka dobija posebno izražen značaj u svetlu principa *Garbage In, Garbage Out (GIGO)*, koji u domenu generativnih transformera dobija nove, kompleksnije implikacije. Za razliku od tradicionalnih modela mašinskog učenja, gde se uticaj nekvalitetnih podataka primarno ogledao u smanjenoj preciznosti klasifikacije, kod *Decoder-only* arhitektura posledice su dalekosežnije i teže za kvantifikaciju. Budući da ovi modeli funkcionišu na principu autoregresivnog predviđanja verovatnoće narednog tokena, oni inherentno internalizuju sve statističke anomalije, logičke nekonzistentnosti i faktografske greške prisutne u ulaznom korpusu. Shodno tome, prisustvo šuma i faktografskih grešaka u podacima može povećati verovatnoću generisanja netačnih ili haluciniranih odgovora, jer model optimizuje verovatnosnu distribuciju bez eksplicitnog mehanizma provere istinitosti. U tom smislu, predobrada i filtriranje predstavljaju ključni mehanizam kontrole distribucije nad kojom se model optimizuje, čime direktno utiču na stabilnost i pouzdanost generisanih izlaza.

Primarni cilj ovog rada jeste sistematična analiza evolucije tehnika predobrade podataka i njihove uloge u optimizaciji performansi *Decoder-only* transformatorskih modela. Istraživanje teži da dekonstruiše prelaz sa tradicionalnih, statičkih metoda čišćenja teksta, zasnovanih na heuristikama i regularnim izrazima, ka savremenim, dinamičkim pristupima koji podrazumevaju kuraciju podataka potpomognutu veštačkom inteligencijom. U radu će se detaljno ispitati kako specifični parametri kvaliteta, kao što su leksička gustina i strukturna koherentnost, utiču na sposobnost modela da generiše semantički ispravan sadržaj. Pored teorijskog okvira, rad ima za cilj da identifikuje optimalne strategije za suzbijanje negativnih efekata unutar masovnih korpusa, pružajući naučno utemeljen uvid u to na koji način rigorozna predobrada služi kao primarna odbrana od faktografske degradacije i sistemske pristrasnosti u generativnim sistemima.

2. Arhitektura *Decoder-only* modela i zavisnost od podataka

Razumevanje kritične uloge kvaliteta podataka zahteva prethodnu analizu arhitektonskih specifičnosti modela koji te podatke procesuiraju. Savremeni jezički modeli velikih razmera primarno su zasnovani na *Decoder-only* varijanti transformatorske arhitekture, koja se distancira od originalnog *encoder-decoder* dizajna usmeravajući se isključivo na generativni aspekt obrade informacija. Dok su ranije arhitekture težile mapiranju ulaznog niza u fiksni vektorski prostor radi klasifikacije ili prevođenja, *Decoder-only* sistemi su dizajnirani za modelovanje distribucije verovatnoće jezika kroz kauzalnu samopažnju (*causal self-attention*). Ova arhitektonska odluka implicira da model ne uči samo semantičke relacije, već i samu strukturu, šum i statističke distorzije prisutne u korpusu. Shodno tome, arhitektura modela i kvalitet podataka ne mogu se posmatrati izolovano; oni čine simbiotski sistem gde strukturni integritet ulaznih informacija direktno određuje kognitivni kapacitet i preciznost finalnog modela.



Slika 1. Arhitektura *Decoder-only* transformera [1]


2.1. Princip rada: *Next-token prediction* i uticaj strukture podataka

Suština obučavanja *Decoder-only* transformera leži u zadatku modelovanja jezika putem predviđanja narednog tokena (*Next-token prediction*). Za datu sekvencu tokena $S = (x_1, x_2, \dots, x_n)$, model nastoji da maksimizuje logaritamsku verovatnoću pojavljivanja svakog narednog elementa na osnovu svih prethodnih, što se formalno može izraziti kroz funkciju verovatnoće:

$$P(S) = \prod_{i=1}^n P(x_i | x_1, \dots, x_{i-1}; \theta) \quad (1)$$

gde θ predstavlja parametre mreže koji se optimizuju tokom procesa učenja. Ovakav autoregresivni pristup implicira da struktura podataka igra odlučujuću ulogu u formiranju unutrašnjih reprezentacija modela. Ukoliko ulazni podaci poseduju visoku stopu koherentnosti i pravilnu sintaksičku strukturu, mehanizam kauzalne samopažnje (*causal self-attention*) uspešno identifikuje dugoročne zavisnosti unutar teksta. Međutim, u situacijama kada je ulazni niz kontaminiran prekidima u logičkom toku, kao što su loše uklonjeni *HTML* tagovi ili fragmentisane rečenice usled agresivnog skraćivanja dokumenata, model biva prisiljen da modeluje statistički šum umesto jezičkih pravila. Takva strukturna degradacija podataka direktno dovodi do povećanja neizvesnosti u predikcijama modela i sporije konvergencije tokom optimizacije.

Specifičnost *Decoder-only* arhitekture ogleda se u primeni mehanizma kauzalne maske (*causal masking*) unutar slojeva samopažnje. Ovaj mehanizam osigurava da pri predviđanju tokena na poziciji i , model može pristupiti isključivo informacijama sa pozicija $j < i$, čime se simulira striktno linearan protok vremena. Međutim, ovakva arhitektonska restrikcija čini model izuzetno ranjivim na kvalitet prethodnog konteksta. Ukoliko je inicijalni segment sekvence zasićen šumom, ortografskim greškama ili semantičkim nebulozama, mehanizam pažnje će takve reprezentacije inkorporirati u kontekstualne projekcije, koje se kroz rezidualne veze i višeslojne transformacije propagiraju ka višim slojevima mreže. U procesu poznatom kao autoregresivna amplifikacija greške, model biva primoran da gradi buduća predviđanja na nestabilnim temeljima, što u fazi generisanja teksta rezultira kumulativnim padom koherentnosti. Dakle, kauzalna maska ne definiše samo smer učenja, već služi i kao transmisioni kanal kroz koji se loš kvalitet ulaznih podataka direktno projektuje na finalni izlaz modela.



Slika 2. Casual Mask [2]

2.2. Pre-training (kvantitet) vs. Fine-tuning (kvalitet)

Razlika u zahtevima za podacima unutar životnog ciklusa jednog transformera najbolje se ogleda u distinkciji između faza primarnog obučavanja i naknadnog finog podešavanja. U fazi pre-treninga, primarni cilj je izlaganje modela što širem spektru jezičkih pojava, gde kvantitet podataka igra presudnu ulogu u formiranju bazičnog svetskog znanja i lingvističke kompetencije. Nasuprot tome, faza *fine-tuninga* (kao i njene varijacije poput instrukcijskog podešavanja) zahteva drastično manji, ali visokokvalitetan i strogo kuriran skup podataka koji služi za usmeravanje modela ka specifičnim zadacima ili željenom tonu komunikacije. Dok prva faza toleriše određeni stepen varijacije u kvalitetu zarad postizanja statističke robusnosti na trilionima tokena, druga faza je izuzetno osetljiva na svaku devijaciju, jer čak i mali broj neadekvatnih primera može narušiti prethodno stečeno znanje ili uvesti nepoželjne obrasce ponašanja.

2.3. Aktuelni modeli i izvori njihovih podataka

Evolucija savremenih sistema, od pionirskih verzija *GPT* serije do najnovijih iteracija poput *Llama 3* i *GPT-4*, neraskidivo je povezana sa razvojem masovnih digitalnih rezervoara teksta. Dok su rani modeli koristili relativno homogene skupove podataka, poput *BookCorpus* ili *Wikipedia* baze, savremeni sistemi se oslanjaju na heterogene izvore koji obuhvataju značajan deo celokupnog

javnog interneta. Ključni izvor za većinu ovih modela je *Common Crawl*, ogromna baza indeksiranih veb stranica koja pruža neophodan kvantitet, ali istovremeno predstavlja najveći izazov u pogledu čistoće podataka. Kako bi se prevazišao ekstremno visok nivo šuma unutar sirovog veb sadržaja, razvijeni su specijalizovani korpusi poput *C4 (Colossal Clean Crawled Corpus)*, koji koristi rigorozne heuristike za uklanjanje redundantnih i niskokvalitetnih fragmenata, te *The Pile*, koji teži ka maksimalnom diverzitetu kombinovanjem akademskih publikacija, programskog koda i pravnih dokumenata. Analiza ovih izvora otkriva da uspeh modela ne zavisi samo od sirove zapremine teksta izražene u terabajtima, već od sofisticiranosti algoritama koji vrše primarnu selekciju informacija pre samog procesa obučavanja.

3. Dimenzije kvaliteta tekstualnih podataka

Definisanje kvaliteta u kontekstu nestrukturiranih tekstualnih informacija predstavlja složen izazov koji prevazilazi jednostavnu binarnu klasifikaciju na ispravne i neispravne podatke. Kvalitet korpusa se u savremenom mašinskom učenju posmatra kroz višedimenzionalni okvir koji obuhvata statistička svojstva, tehničku čistotu i semantički integritet sadržaja. Dok su rani pristupi predobradi bili fokusirani prvenstveno na uklanjanje očiglednog šuma, razvoj kompleksnih generativnih sistema nametnuo je potrebu za dubljom analizom leksičkih parametara i strukture dokumenata. Razumevanje ovih dimenzija je ključno, jer svaka anomalija u ulaznim podacima – bilo da je reč o statističkoj monotoniji, prisustvu tehničkih artefakata ili kontaminaciji testnim primerima – direktno utiče na sposobnost modela da generalizuje znanje i zadrži visok stepen kreativnosti bez gubitka činjenične tačnosti.

3.1. Leksički parametri

Statistička analiza leksičkog sastava korpusa pruža inicijalni uvid u njegovu informativnu vrednost. Jedan od osnovnih indikatora kvaliteta je **dužina dokumenata**, koja mora biti u skladu sa predviđenim kontekstnim prozorom modela. Previše kratki dokumenti često ne sadrže dovoljno informacija za uspostavljanje složenih semantičkih veza, dok ekstremno dugački tekstovi bez jasne strukture mogu opteretiti mehanizme pažnje nepotrebnim redundansama.

Pored dužine, **obim rečnika** (*vocabulary size*) i **indeks leksičkog diverziteta** predstavljaju ključne metrike za izbegavanje fenomena jezičke osiromašenosti. Leksički diverzitet se često kvantifikuje putem *Type-Token Ratio (TTR)* metrike, koja predstavlja odnos jedinstvenih reči i ukupnog broja reči u tekstu:

$$TTR = \frac{V}{N} \quad (2)$$

gde V označava broj jedinstvenih leksema, a N ukupan broj tokena u uzorku. Visoka vrednost ovog indeksa ukazuje na bogat i raznovrstan korpus, što je neophodan preduslov da model razvije širok spektar izražajnih mogućnosti. Nasuprot tome, nizak diverzitet, često uzrokovan repetitivnim frazama ili mašinski generisanim spamom, može dovesti do toga da model postane statistički zarobljen u uskom podskupu jezika, što rezultira monotonim i predvidljivim generisanjem teksta.

Jedan od najpouzdanijih indikatora prirodnosti i kvaliteta korpusa je usklađenost sa **Zipfovim zakonom** (*Zipf's Law*). Ovaj empirijski zakon postavlja da je frekvencija bilo koje reči u jeziku obrnuto proporcionalna njenom rang u tabeli učestalosti. Matematički se to izražava formulom:

$$P_r = \frac{C}{r^\alpha} \quad (3)$$

gde je P_r verovatnoća pojave reči ranga r , C je konstanta, a eksponent α je obično blizu vrednosti 1. U kontekstu predobrade za velike jezičke modele, značajna odstupanja od ove distribucije unutar dokumenta često ukazuju na nizak kvalitet podataka. Na primer, prekomerena zastupljenost određenih ključnih reči, karakteristična za tekstove optimizovane za pretraživače (*SEO spam*), ili ekstremno mali broj jedinstvenih leksema u dugim nizovima, signaliziraju da podatak nema

prirodnu jezičku strukturu. Takvi dokumenti se u fazi filtriranja često odbacuju jer ne doprinose generalizaciji, već mogu dovesti do toga da model postane sklon besciljnom ponavljanju fraza.

U praktičnoj primeni, proces selekcije podataka oslanja se na strogo definisane **heurističke pragove** koji služe kao inicijalni filteri kvaliteta. Istraživački timovi (poput onih koji su radili na modelima *GPT-3* i *Llama*) primenjuju set pravila zasnovanih na statističkim ekstremima. Primera radi, dokumenti se automatski eliminišu ukoliko imaju:

- **Ekstremnu dužinu reči:** Prosečna dužina reči koja značajno odstupa od proseka datog jezika (npr. preko 15 karaktera u engleskom jeziku) često ukazuje na prisustvo programskog koda, hemijskih formula ili nasumičnih karaktera.
- **Nizak udeo stop-reči:** Ako dokument sadrži premalo funkcionalnih reči (kao što su predlozi i veznici), verovatno je reč o listi proizvoda, tabelarnim podacima ili generisanom spamu, a ne o tečnom tekstu.
- **Visok procenat simbola:** Dokumenti u kojima dominiraju interpukcijski znaci, emoji ili numerički simboli u odnosu na alfabetske karaktere smatraju se šumom koji može degradirati proces učenja.

Dodatna metrika koja rešava ograničenja sirovog TTR-a (odnos broja različitih reči i ukupnog broja reči) jeste **unigramska entropija**, preuzeta iz teorije informacija. Dok TTR meri udeo jedinstvenih reči, on ne uzima u obzir koliko su te reči ravnomerno raspoređene kroz dokument. Unigramska entropija rešava ovaj problem merenjem nepredvidivosti distribucije reči, a izračunava se kao:

$$H = - \sum \left(\frac{\text{count}(w)}{N} \right) \log \left(\frac{\text{count}(w)}{N} \right) \quad (4)$$

gde se suma odnosi na sve jedinstvene reči w u dokumentu, a N predstavlja ukupan broj reči. Dokument u kojem jedna reč dominira imaće nisku entropiju bez obzira na njegov TTR, što ovu metriku čini pouzdanijim pokazateljem **vokabularne raznovrsnosti**.

U praksi, visokokvalitetni korpusi prirodnog jezika obično pokazuju vrednosti entropije između **5,0 i 7,0**, dok vrednosti ispod **3,0** ukazuju na lingvističko osiromašenje – fraze koje se ponavljaju, mašinski generisan sadržaj ili fragmente strukturalnih podataka pre nego tečan tekst.

3.2. Šum u masovnim podacima

Prisustvo šuma u korpusima namenjenim obučavanju *Decoder-only* transformera predstavlja neizbežnu posledicu korišćenja automatizovanih metoda prikupljanja podataka, kao što je *web scraping*. Šum se može klasifikovati u dve osnovne kategorije:

- **Tehnički artefakti:** obuhvataju zaostale **HTML tagove**, metapodatke i JavaScript fragmente koji, ukoliko nisu adekvatno uklonjeni, primoravaju model da troši dragocene

parametre na učenje sintakse obeležavanja umesto prirodnog jezika. Prisustvo rezidualnih *HTML* elemenata, poput tagova `<div>` ili karaktera za razmak bez prekida (` `), predstavlja značajan teret za proces tokenizacije. Savremeni modeli koriste ograničen kontekstni prozor (npr. 8.192 ili 32.768 tokena). Kada dokument sadrži neprečišćen *HTML* kod, svaki simbol i tag se konvertuju u zasebne tokene, trošeći dragoceni memorijski prostor koji bi trebalo da bude rezervisan za semantički relevantan tekst. Na primer, niz `   ` može biti tokenizovan kao tri ili više zasebnih jedinica, što veštački produžava sekvencu i primorava mehanizam pažnje da obrađuje statički šum. Ovakva redundansa direktno smanjuje efikasnost modela, jer on troši svoje računске resurse na učenje sintakse obeležavanja veb stranica umesto na razumevanje logičkih veza unutar prirodnog jezika. Poseban izazov predstavljaju **OCR greške** (*Optical Character Recognition*) nastale pri digitalizaciji štampanih materijala, gde pogrešno prepoznati karakteri stvaraju nepostojeće lekseme i povećavaju entropiju rečnika. Tipičan primer je vizuelna sličnost karaktera, gde se malo slovo „l“ prepoznaje kao broj „1“, ili slovo „o“ kao nula „0“. U rečenici poput „*The level of quality is high*“, OCR greška može generisati niz „*The level of quality is high*“. Za model, reč „*level*“ predstavlja potpuno novi, nepoznati token koji nema semantičku vezu sa originalnom reči „*level*“. Ovakve greške fragmentišu rečnik modela, povećavaju entropiju i onemogućavaju pravilnu generalizaciju, jer model tretira ove tipfelere kao legitimne, ali nepovezane lingvističke entitete.

- **Semantička degradacija:** ogleda se kroz **boilerplate tekst**, koji uključuje repetitivne elemente poput navigacionih menija, pravnih napomena u podnožju stranica i agresivnih reklamnih sadržaja. Ovi elementi ne samo da unose nepotrebnu redundansu, već mogu distorzirati pažnju modela, slabeći njegovu sposobnost da uspostavi koherentne veze unutar primarnog sadržaja dokumenta. Glavni problem kod ovih podataka je njihova visoka frekvencija pojavljivanja uz minimalnu informativnu vrednost. Ako se u trening setu nađe milion stranica koje u podnožju sadrže identičan tekst o uslovima korišćenja, model će statistički favorizovati taj niz, što može dovesti do preteranog prilagođavanja (*overfitting*) na administrativni rečnik. Takođe, boilerplate tekst često prekida prirodni tok rečenica; na primer, usred pasusa se može naći fragment menija „*Home | Products | Contact*“, što zbunjuje mehanizam pažnje i otežava učenje dugoročnih zavisnosti unutar teksta. Filtriranje ovakvog sadržaja je neophodno kako bi se osiguralo da model uči iz tečnog, koherentnog ljudskog izražavanja, a ne iz tehničke strukture veb prezentacija.

3.3. Kontaminacija podataka

Jedan od najkritičnijih izazova u pogledu kvaliteta korpusa za savremene *Decoder-only* modele jeste **kontaminacija podataka** (*data contamination*). Ovaj fenomen podrazumeva nenamerno uključivanje primera iz javno dostupnih testnih skupova (*benchmark* setova) u korpus za obučavanje modela. S obzirom na to da se modeli poput *GPT-4* ili *Llama* obučavaju na masovnim ekstrakcijama sa globalne mreže, velika je verovatnoća da će proces prikupljanja podataka obuhvatiti i stranice poput *GitHub* repozitorijuma, akademskih portala ili platformi kao što je *Hugging Face*, gde se čuvaju pitanja i rešenja za standardne testove inteligencije i znanja (npr. *MMLU*, *GSM8K* ili *HumanEval*).

Problem kontaminacije direktno obesmišljava proces evaluacije modela; umesto da demonstrira sposobnost generalizacije i logičkog zaključivanja, model može jednostavno da recituje

memorisane odgovore koje je video tokom faze obučavanja. Ovakva veštački uvećana preciznost stvara lažnu sliku o kognitivnim kapacitetima sistema, što u naučnoj zajednici izaziva opravdanu sumnju u stvarne performanse *LLM*-a. Identifikacija i uklanjanje kontaminiranih podataka zahteva primenu naprednih metoda predobrade, kao što je *n*-gram preklapanje (*n-gram overlap*) između trening korpusa i testnih setova. Ukoliko se detektuje visok stepen podudarnosti dugih sekvenci tokena, neophodno je izvršiti filtriranje tih dokumenata kako bi se osiguralo da su rezultati evaluacije odraz stvarne inteligencije modela, a ne puke statističke memorizacije rešenja.

Analiza tehničkih izveštaja najmodernijih modela potvrđuje ozbiljnost ovog problema. Autori modela **GPT-3** su u svom izvornom radu priznali grešku u filtriranju, gde je usled бага u kodu deo testnih setova „procureo” u trening korpus. Iako su pokušali da retroaktivno analiziraju uticaj ove kontaminacije, priznali su da je to moglo dovesti do neopravdano visokih rezultata na određenim benchmark testovima.

Slično tome, u tehničkom izveštaju za **Llama 2**, istraživački tim kompanije Meta je posvetio čitavo poglavlje analizi kontaminacije. Oni su sprovedi rigorozno čišćenje koristeći *n*-gram preklapanje (gde je $n = 13$), eliminišući svaki dokument koji je imao više od 13 uzastopnih identičnih tokena sa bilo kojim testnim primerom. Interesantan je nalaz da su čak i nakon takvog čišćenja modeli pokazivali tragove memorizacije, što sugerise da tradicionalne metode filtriranja možda nisu dovoljne da spreče modele da uče napamet široko dostupne internet testove. Ovi primeri naglašavaju da je borba protiv kontaminacije neprekidan proces koji zahteva stalno inoviranje tehnika predobrade.[3][4]

3.4. Algoritamska detekcija preklapanja: *MinHash* i *LSH*

Detekcija kontaminacije na skupovima podataka koji obuhvataju trilion tokena zahteva primenu ekstremno efikasnih algoritama za aproksimativno poređenje nizova. U tom kontekstu, **MinHash** algoritam predstavlja standard za procenu *Jaccard*-ovog indeksa sličnosti između dva dokumenta bez potrebe za njihovim direktnim poređenjem reč po reč. Proces podrazumeva transformaciju dokumenata u skupove *n*-grama, koji se potom putem heš funkcija mapiraju u fiksni niz minimalnih heš vrednosti (*signatures*). Sličnost dva dokumenta procenjuje se na osnovu verovatnoće da su njihove *MinHash* vrednosti identične.

Kako bi se ovaj proces dodatno ubrzao, koristi se **Locality-Sensitive Hashing (LSH)** tehnika. *LSH* grupiše slične *MinHash* potpise u zajedničke kante (*buckets*), čime se prostor pretrage drastično sužava. Umesto da svaki dokument iz ogromnog trening seta upoređuje sa svakim pitanjem iz test seta (operacija složenosti $O(n^2)$), *LSH* omogućava da se poređenje vrši samo unutar istih kanti. Ova metodologija je od vitalnog značaja za očuvanje integriteta modela, jer omogućava istraživačima da u realnom vremenu identifikuju i eliminišu dokumente koji sadrže ne samo identične kopije testnih pitanja, već i njihove bliske varijacije ili parafrazirane verzije.

4. Tehnike preobrade i normalizacije

Napredne tehnike predobrade i normalizacije ne predstavljaju samo opcionalne korake čišćenja, već čine samu srž algoritamskog pajplajna koji definiše kako će model interpretirati lingvističke jedinice. U ovoj fazi, fokus je na rešavanju problema redundanse, jezičke uniformnosti i efikasnosti reprezentacije putem sofisticiranih metoda tokenizacije i deduplikacije. Implementacija ovih tehnika direktno adresira ranije pomenuti GIGO problem, osiguravajući da model troši svoje računске resurse na učenje distinktivnih semantičkih obrazaca, a ne na procesuiranje statistički beznačajnih ponavljanja ili neadekvatno kodiranih karaktera.

4.1. Moderni tokenizatori

Proces tokenizacije predstavlja prvi nivo abstrakcije u kojem se tekstualni niz transformiše u numeričke vektore razumljive neuronskoj mreži. Dok su stariji modeli koristili tokenizaciju na nivou celih reči ili pojedinačnih karaktera, savremeni sistemi se oslanjaju na metode **podreči** (*subword tokenization*), prvenstveno **Byte-Pair Encoding (BPE)** i **SentencePiece**.

BPE funkcioniše putem iterativnog spajanja najčešćih parova susednih karaktera u nove, duže tokene. Ovaj pristup omogućava modelu da balansira između efikasnosti (za česte reči) i fleksibilnosti (razbijanjem retkih ili nepoznatih reči na smislene morfeme). S druge strane, **SentencePiece** uvodi dodatnu inovaciju tretirajući razmak kao simbol, što omogućava uniformnu obradu bez obzira na specifičnosti jezika, izbegavajući potrebu za pre-tokenizacijom zasnovanom na specifičnim jezičkim pravilima.

Kvalitet algoritma za tokenizaciju direktno utiče na performanse modela u domenima koji zahtevaju preciznost, kao što su matematika i programiranje:

- **Interpretacija brojeva:** Ukoliko tokenizator razbija višecifrene brojeve na nekonzistentne fragmente (npr. broj "1024" vidi kao "10" i "24", dok "1025" vidi kao "1", "0" i "25"), model će imati značajne poteškoće u učenju aritmetičkih operacija i numeričkih relacija.
- **Razumevanje programskog koda:** U jezicima poput *Python-a*, gde je uvlačenje reda (*indentation*) ključno za logiku koda, loša tokenizacija koja ignoriše ili nepravilno spaja prazne prostore može učiniti kod potpuno nefunkcionalnim za model.

4.2. Deduplikacija

Deduplikacija dokumenata u korpusima namenjenim generativnim modelima deli se na dva nivoa: **egzaktnu** i **neegzaktnu** (*fuzzy*) deduplikaciju. Egzaktna deduplikacija uklanja identične kopije dokumenata koje su nastale usled višestrukog indeksiranja istih stranica od strane *web crawler-a*. Međutim, daleko veći izazov predstavlja neegzaktna deduplikacija, kojom se identifikuju dokumenti sa minimalnim varijacijama (npr. iste vesti objavljene na različitim portalima sa drugačijim zaglavlјima). Kao što je ranije pomenuto u kontekstu kontaminacije, algoritmi poput **MinHash** i **LSH** ovde nalaze svoju primarnu primenu, omogućavajući poređenje semantičke sličnosti dokumenata na nivou trilion primerama.

4.2.1. Repetition Loop

Ključni razlog za rigoroznu deduplikaciju leži u prevenciji fenomena gde model zaglavljuje u beskonačnim repetitivnim petljama tokom faze inferencije. Istraživanja su pokazala da ukoliko se određena sekvenca ili stil pisanja pojavljuju prekomerno u trening setu, model tim sekvencama dodeljuje neproporcionalno visoku verovatnoću. Rezultat je model koji, nakon nekoliko generisanih rečenica, upada u petlju ponavljanja istih fraza, jer je kroz redundantne podatke naučio da je statistički najverovatniji nastavak teksta upravo ono što je malopre napisao.

4.2.2. Memorizacija i generalizacija

Pored stabilnosti generisanja, deduplikacija direktno utiče na sposobnost generalizacije. Modeli koji se obučavaju na dupliranom sadržaju imaju tendenciju ka **memorizaciji** (*overfitting*) umesto ka razumevanju logičkih koncepata. Uklanjanjem duplikata, model se primorava da uči univerzalne jezičke obrasce iz raznovrsnijih izvora, što značajno smanjuje rizik od doslovnog reprodukovanja (plagiranja) delova trening seta. U modernim pajplajnim, poput onog korišćenog za *Llama 3*, deduplikacija se vrši na više nivoa, od nivoa rečenice do nivoa celokupnog dokumenta, čime se efektivni broj tokena može smanjiti i do 30%, ali se istovremeno dramatično povećava informativna gustina preostalih podataka.

4.2.3. Jaccard-ov indeks sličnosti

Jaccardov indeks sličnosti se koristi za poređenje skupova n -grama dva dokumenta (A i B). Matematički, ovaj indeks predstavlja odnos preseka i unije skupova tokena:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (5)$$

U praktičnoj primeni na masovnim korpusima, istraživači najčešće postavljaju pragove između **0.8** i **0.9**. Dokumenti čiji *Jaccardov* indeks prelazi ovu vrednost smatraju se redundantnim i biva zadržana samo jedna reprezentativna kopija. Ovakva granulacija omogućava sistemu da prepozna i eliminiše varijacije istog sadržaja (npr. članke koji se razlikuju samo u datumu ili nazivu grada), čime se direktno preventuje prevelika količina određenih statističkih putanja unutar neuronske mreže.

Pored poboljšanja kvaliteta generisanja, deduplikacija ima i kritičnu ekonomsku opravdanost. Obučavanje modela sa stotinama milijardi parametara zahteva hiljade *GPU* sati, gde svaki nepotrebno procesuirani trilion tokena košta milione dolara u električnoj energiji i računarskim resursima. Efikasna deduplikacija može smanjiti sirovi skup podataka za **20%** do **40%** bez degradacije performansi modela. U naučnoj literaturi se ovaj fenomen često opisuje kao povećanje informativne gustine korpusa [6]; model dostiže isti ili viši nivo kompetencije (*benchmark* rezultate) u kraćem vremenskom periodu jer se proces učenja fokusira isključivo na jedinstvene informacione jedinice. Na taj način, rigorozna predobrada postaje ključni faktor u demokratizaciji razvoja *LLM* modela, omogućavajući postizanje vrhunskih rezultata uz optimizovanu potrošnju hardverskih kapaciteta.

4.3. Jezička identifikacija

Proces **jezičke identifikacije** (*Language Identification - LID*) predstavlja primarni filter u izgradnji korpusa, čiji je zadatak precizno razvrstavanje dokumenata prema jeziku na kojem su napisani. U eri višejezičnih modela, ovaj korak je ključan za kontrolu distribucije znanja; ukoliko se u trening setu za specifičan jezik (npr. srpski) nađe značajan procenat dokumenata na srodnim jezicima ili engleskom, model može razviti tendenciju ka kodnom mešanju (*code-switching*) ili sintaksičkoj kontaminaciji. Savremeni sistemi koriste brze klasifikatore zasnovane na n-gramima karaktera ili lagane neuronske mreže, poput *FastText* modela, koji postižu visoku preciznost čak i na kratkim fragmentima teksta. Dokumenti za koje klasifikator ne može da utvrdi jezik sa visokim stepenom pouzdanosti (obično iznad 0,9) najčešće se odbacuju, jer se pretpostavlja da sadrže preveliku količinu šuma, programskog koda ili su jednostavno besmisleni nizovi karaktera.

Nakon identifikacije jezika, sledi faza **normalizacije**, koja ima za cilj svođenje teksta na standardizovanu formu bez gubitka semantičkih informacija. Normalizacija u kontekstu *LLM*-a obuhvata nekoliko kritičnih operacija:

- **Unifikacija Unicode karaktera:** Rešavanje problema različitih kodnih stranica i normalizacija vizuelno identičnih simbola koji imaju različite digitalne reprezentacije, čime se sprečava nepotrebno širenje rečnika.
- **Tretman interpukcije i belina:** Standardizacija razmaka, uklanjanje kontrolnih karaktera i unifikacija različitih tipova navodnika i crtica, što direktno utiče na konzistentnost tokenizacije.
- **Dekodiranje HTML entiteta:** Transformacija simbola poput `&` ili `<` u njihove tekstualne ekvivalente (`&` i `<`), osiguravajući da model uči iz prirodnih simbola, a ne iz njihovih veb-kodiranih zamena.

Pravilno sprovedena jezička identifikacija i normalizacija osiguravaju da model gradi robusne vektorske reprezentacije na čistim, uniformnim podacima. Bez ovih koraka, model bi bio primoran da troši svoj kapacitet na učenje varijacija u kodiranju istih jezičkih simbola, što bi rezultiralo smanjenom efikasnošću i lošijom generalizacijom na retkim jezicima gde je svaki ispravan token od presudne važnosti.

Poseban fokus u procesu predobrade mora biti stavljen na jezike sa niskim resursima, gde je količina dostupnih digitalnih podataka značajno manja u poređenju sa globalnim jezicima poput engleskog ili kineskog. Kod ovakvih jezika, svaki dokument ima veću relativnu težinu u formiranju unutrašnjih reprezentacija modela. Stoga, preterano agresivno filtriranje i strogi pragovi identifikacije jezika mogu biti kontraproduktivni, jer mogu dovesti do eliminacije retkih, ali visokokvalitetnih izvora informacija. Strategija normalizacije za ove jezike često zahteva finije podešavanje; na primer, kod srpskog jezika neophodno je osigurati pravilno mapiranje između ćiriličnog i latiničnog pisma kako model ne bi tretirao isti jezik kao dva potpuno različita entiteta, čime bi se efektivni kapacitet učenja praktično prepолоvio.

Dodatnu kompleksnost jezičkoj identifikaciji nameće prisustvo dijalekata, lokalizama i neformalnog internet govora. Standardni *LID* algoritmi (poput *FastText*-a) često su obučavani na formalnim tekstovima (*Wikipedia*, novinske agencije), zbog čega mogu pogrešno klasifikovati

dijalekte ili arhaične forme kao šum ili kao drugi, srodni jezik. Na primer, tekstovi na torlačkom dijalektu ili specifični regionalni izrazi mogu biti odbačeni kao nepoznati ili neispravni. U modernoj predobradi, ovaj problem se rešava uvođenjem inkluzivnijih klasifikatora koji prepoznaju varijacije unutar istog jezičkog koda. Cilj je očuvanje lingvističkog diverziteta, jer upravo ovi podaci omogućavaju modelu da razvije prirodniji ton komunikacije i bolje razumevanje specifičnog kulturnog konteksta koji standardni korpusi često ne sadrže.

5. Kuracija podataka i poravnanje (Alignment)

Nakon što se sirovi podaci podvrgnu tehničkoj normalizaciji i deduplikaciji, nastupa kritična faza **kuracije**, koja transformiše kvantitet u upotrebnu vrednost. Kuracija podataka predstavlja proces selektivnog filtriranja i kategorizacije informacija sa ciljem da se model izloži samo onim primerima koji podstiču razvoj željenih kognitivnih sposobnosti. Dok je rana faza obučavanja fokusirana na apsorpciju što većeg broja informacija, faza **poravnanja** (*alignment*) služi kao finalni nivo predobrade koji osigurava da izlaz modela bude ne samo tačan, već i bezbedan, koristan i usklađen sa ljudskim vrednostima. Ovaj proces kombinuje automatizovane heuristike, klasifikatore zasnovane na veštačkoj inteligenciji i direktnu ljudsku povratnu informaciju, čineći granicu između sirovog podatka i inteligentnog odgovora jasnom i kontrolisanom.

5.1. Heurističko filtriranje: Lingvistička pravila i bezbednost

Prvi nivo kuracije oslanja se na skup strogo definisanih **heuristika** koje služe za masovno eliminisanje dokumenata koji, uprkos tehničkoj ispravnosti, nemaju edukativnu ili informativnu vrednost. Ove heuristike se najčešće baziraju na statističkim odnosima unutar teksta:

- **Odnos reči i brojeva:** Dokumenti u kojima dominiraju numerički podaci bez pratećeg tekstualnog objašnjenja (poput ogromnih tabela ili *log* fajlova) često se odbacuju jer ne doprinose učenju jezičkih struktura.
- **Prisustvo toksičnog sadržaja:** Primena crnih listi reči (psovki, govora mržnje, eksplicitnog sadržaja) služi kao primarna barijera. Ipak, moderna predobrada ovde mora biti pažljiva da ne eliminiše važne istorijske, književne ili medicinske dokumente koji mogu sadržati osetljive termine u naučnom kontekstu. Ovakva sterilizacija, ne samo da ograničava opšte znanje modela, već ga može učiniti nesposobnim da prepozna i adekvatno reaguje na neadekvatan sadržaj u realnim interakcijama. Savremena istraživanja sugerisu da je umesto potpunog brisanja, efikasnije koristiti ponderisanje podataka, gde se kontroverzni, ali informativni sadržaji zadržavaju uz posebne oznake (*metadata tags*) koje usmeravaju model ka objektivnom tonu.
- **Kvalitet rečenica:** Heuristike proveravaju da li rečenice počinju velikim slovom i završavaju se znakom interpunkcije. Dokumenti sa prevelikim brojem gramatički neispravnih fragmenata se markiraju kao niski kvalitet.

U praksi, većina istraživačkih timova danas prati stroge protokole uspostavljene tokom razvoja modela kao što su **Gopher** (*DeepMind*) i **C4** (*Google*). **Gopher protocol** uvodi set pravila zasnovanih na statističkim pragovima, gde se, na primer, odbacuje svaki dokument kod kojeg odnos simbola i reči prelazi određenu granicu, ili gde je udeo stop-reči (npr. „i“, „da“, „na“) suviše nizak, što obično signalizira da je tekst generisan robotski. S druge strane, **C4** (*Colossal Clean Crawled Corpus*) standard se fokusira na eliminaciju repetitivnih elemenata („lorem ipsum“ tekstova) i filtriranje na osnovu dužine rečenica. Ovi standardi su postali temelj moderne kuracije jer omogućavaju da se od stotina terabajta sirovih podataka sa *Common Crawl*-a dođe do visokokvalitetne baze koja zadržava lingvističku raznovrsnost, istovremeno minimizujući prisustvo šuma.

5.2. Filtriranje zasnovano na modelu

Kada se iscrpe mogućnosti heurističkog filtriranja, nastupa faza **model-based filtering-a**, gde se koriste manji, specijalizovani modeli mašinskog učenja za donošenje kvalitativnih sudova o tekstu. Dok su heuristike fokusirane na površinsku strukturu, ovi modeli (poput **fastText** klasifikatora ili specifičnih varijanti **BERT-a**) obučeni su da prepoznaju semantičku vrednost dokumenta. Glavni cilj je binarna ili gradirana klasifikacija sadržaja na **High-quality** (informativan, koherentan tekst) i **Low-quality** (spam, mašinski generisan sadržaj, fragmentisane misli). Ovaj proces se najčešće odvija u dva koraka:

1. **Obučavanje klasifikatora na zlatnom standardu:** Istraživači ručno kuriraju manji skup podataka (npr. članke sa Vikipedije, odabrane naučne radove i kvalitetne knjige) koji služe kao pozitivan primer. Kao negativni primeri koriste se nasumični, nefiltrirani delovi *web crawl* korpusa.
2. **Masovna inferencija:** Pomoćni model (klasifikator) potom prolazi kroz milijarde dokumenata i svakom dodeljuje *score* kvaliteta. Dokumenti čija je verovatnoća korisnosti ispod određenog praga (npr. $P < 0,65$) automatski se eliminišu iz finalnog trening seta.

Prednost ovog pristupa je u njegovoj sposobnosti da prepozna suptilne nijanse koje ljudsko oko lako uočava, ali koje je teško definisati kodom. Na primer, model može uspešno identifikovati tekst koji je gramatički ispravan, ali informativno prazan ili repetitivan (*gibberish*). Korišćenje modela poput *fastText*-a je ovde posebno popularno zbog njegove ekstremne brzine; on može procesuirati stotine hiljada tokena u sekundi, što ga čini ekonomski isplativim za filtriranje korpusa koji se mere u terabajtima. Na taj način, pomoćni modeli deluju kao inteligentno sito koje osigurava da glavni model tokom obučavanja troši računarsku snagu isključivo na visokokvalitetne lingvističke reprezentacije.

Pored klasifikatora, jedna od najefikasnijih tehnika za filtriranje masovnih korpusa je merenje **perplexity** (perpleksnosti) dokumenta pomoću manjeg, već obučenog modela. Perplexity je mera koliko je određeni tekst iznenađujuć za model; matematički, ona predstavlja eksponent unakrsne entropije (*cross-entropy*):

$$PP(W) = P(w_1, w_2, \dots, w_N)^{-\frac{1}{N}} \quad (6)$$

gde je $P(w_1, w_2, \dots, w_N)$ verovatnoća celokupnog tekstualnog niza W , a N je dužina teksta. Za nizak PP (npr. $< 10-50$), tekst je previše predvidljiv. To su često nizovi poput „*ovde ide tekst ovde ide tekst*“ ili automatski generisani logovi servera. Model iz ovoga ne uči ništa novo, već samo utvrđuje suvišne, bazične obrasce. Za visok PP (npr. $> 200-300$, zavisno od modela), tekst je haotičan. To su često nasumično nabacane reči za *SEO* optimizaciju, tekstovi na jeziku koji model ne prepoznaje ili dokumenti sa toliko *OCR* grešaka da su izgubili semantički smisao. U praksi predobrade, dokumenti sa ekstremno niskom ili ekstremno visokom perpleksnošću se najčešće odbacuju. Postavljanjem optimalnih pragova za perpleksnost, istraživači osiguravaju da trening set sadrži tekstove koji su dovoljno predvidljivi da budu razumljivi, ali i dovoljno informativni da podstaknu učenje kompleksnih zavisnosti.

Uvođenje modela kao sudija kvaliteta donosi rizik od sistemske pristrasnosti. Budući da se ovi klasifikatori obučavaju na podacima koje su ljudi označili kao visokokvalitetne (poput enciklopedijskih članaka ili pravnih dokumenata), oni teže da favorizuju isključivo formalni i akademski stil pisanja. Ovo može dovesti do nenamernog eliminisanja neformalnih, ali dragocenih izvora poput foruma, dijaloga na društvenim mrežama ili kreativnog pisanja, koji su ključni za učenje kolokvijalnog govora i slenga. Ako klasifikator postane suviše rigidan, model koji se obučava na tako pročišćenom korpusu može postati sposoban da piše naučne radove, ali potpuno neuspešan u razumevanju svakodnevne ljudske komunikacije ili specifičnih kulturnih nijansi. Rešavanje ovog problema zahteva pažljivo balansiranje trening seta za same klasifikatore, kako bi se osiguralo da visok kvalitet obuhvati širok spektar ljudskog izražavanja, a ne samo strogo formalni diskurs.

5.3. *SFT i RLHF*

Iako masovna predobrada i automatizovano filtriranje uklanjaju tehnički šum, oni ne mogu garantovati da će model biti koristan, bezbedan ili usklađen sa ljudskim namerama. Zbog toga se u završnoj fazi pripreme podataka uvode ***Supervised Fine-Tuning (SFT)*** i ***Reinforcement Learning from Human Feedback (RLHF)***. Ove metode predstavljaju specifičan oblik kuracije gde se akcenat pomera sa kvantiteta na ekstremni kvalitet i preciznost informacija.

SFT se oslanja na visokokvalitetne skupove podataka koje su kreirali ili verifikovali ljudi (obično stručnjaci za određene oblasti). Ovi podaci se sastoje od parova instrukcija-odgovor (npr. „*Objasni množenje matrica detetu od 5 godina*” – praćeno idealnim odgovorom). U ovoj fazi, predobrada se fokusira na eliminaciju bilo kakve dvosmislenosti; svaki odgovor mora biti činjenično tačan, stilski ujednačen i lišen pristrasnosti. *SFT* služi kao zlatni standard koji model uči osnovama dijaloga i rešavanja zadataka.

RLHF predstavlja još napredniji nivo obrade, gde ljudi ne pišu direktne odgovore, već rangiraju izlaze modela. Proces teče kroz nekoliko koraka:

1. Model generiše nekoliko različitih odgovora na isti upit.
2. Ljudski evaluatori rangiraju te odgovore (npr. od najboljeg do najgoreg) na osnovu kriterijuma kao što su istinitost, korisnost i bezbednost.
3. Ove rang-liste se koriste za obučavanje modela nagrade (*Reward Model*), koji potom služi kao automatski kritičar koji kažnjava loše i nagrađuje dobre odgovore tokom daljeg učenja.

Ova faza je ključna za rešavanje problema toksičnosti i bezbednosti koje automatizovani filteri nisu mogli u potpunosti da otklone. Ljudski *feedback* omogućava modelu da razume suptilne kontekste, ironiju ili potencijalno opasne upite koji su gramatički ispravni, ali etički neprihvatljivi. Na taj način, *RLHF* i *SFT* deluju kao vrhunski filteri koji model iz pasivnog skladišta informacija transformišu u proaktivan i bezbedan sistem spreman za interakciju sa korisnicima.

6. Uloga semantičkih modela u modernoj predobradi

Dok su prethodne faze fokusirane na uklanjanje šuma i očigledno loših podataka, savremena predobrada uvodi koncept **semantičke filtracije**. Cilj više nije samo imati "čist" tekst, već tekst koji poseduje visoku **obrazovnu vrednost**. Ovde se vektorski prostori i semantički *embedding*-zi koriste za mapiranje celokupnog znanja unutar korpusa, omogućavajući istraživačima da balansiraju teme i identifikuju najinformativnije delove interneta.[9][10]

Umesto da posmatramo reči, moderni sistemi koriste modele za ugnježdavanje (*embeddings*) kako bi dokumente pretvorili u vektore u višedimenzionalnom prostoru. Koristeći algoritme za klasterovanje (poput *k-means*), istraživači mogu identifikovati tematske grupe unutar triliona dokumenata. Ovo je ključno za:

- **Identifikaciju retkih domena:** Pronalaženje visokokvalitetnih tekstova o kvantnoj fizici ili retkim programskim jezicima koji bi inače bili zasenjeni u moru vesti o slavnim ličnostima.
- **Balansiranje diverziteta:** Ako 90% korpusa čine vesti, model će biti pristrasan. Semantičko klasterovanje omogućava inženjerima da namerno uzorkuju podatke tako da svaka tema (nauka, umetnost, kod, pravo) bude zastupljena u optimalnom odnosu, bez obzira na to koliko je često zastupljena na sirovom internetu.

Sličnost između dva dokumenta u ovom prostoru najčešće se računa putem **kosinusne sličnosti** (*cosine similarity*):

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} \quad (7)$$

Gde su A i B vektorske reprezentacije dokumenata. Što je vrednost bliža 1, to su dokumenti semantički srodniji, što omogućava još precizniju deduplikaciju nego što to nudi MinHash.

6.1. LLM-as-a-Judge

U potrazi za savršenim trening setom, istraživači su uveli metodologiju gde jedan visoko razvijen model (poput *GPT-4* ili *Claude 3*) služi kao sudija (*judge*) koji procenjuje kvalitet sirovih podataka za obučavanje manjih ili novih modela. Ovaj proces prevazilazi binarno filtriranje i uvodi gradiranu skalu kvaliteta. Model-sudija dobija instrukciju da oceni dokument na skali od 1 do 10 na osnovu specifičnih kriterijuma: **logičke koherentnosti, informativne gustine i odsustva semantičkog šuma**. Na ovaj način, proces predobrade dobija novu dimenziju – **kvalitativno rangiranje**. Dokumenti koji dobiju niske ocene (npr. ispod 3) se trajno odbacuju, dok se oni sa najvišim ocenama (iznad 8) višestruko ponavljaju u trening setu (*up-sampling*). Ovakva stratifikacija omogućava modelu da tokom procesa učenja provede više vremena analizirajući visokokvalitetne tekstove, što dramatično ubrzava konvergenciju i poboljšava sposobnost rešavanja kompleksnih zadataka.

Direktna primena *LLM-as-a-Judge* koncepta najbolje je ilustrovana u Microsoft-ovom istraživanju pod naslovom „*Textbooks Are All You Need*” [11], koje je rezultiralo serijom modela ***Phi***. Suština ovog pristupa je radikalna selekcija: umesto da se model obučava na celom internetu koji je pun šuma, on se obučava isključivo na podacima koji imaju strukturu i kvalitet sličan školskim udžbenicima. Rezultati su pokazali da model obučen na svega **1%** originalno planiranih podataka, ali ekstremno visokog semantičkog kvaliteta, može nadmašiti modele koji su 50 puta veći, a obučeni na neobrađenom internet šumu.

7. Evolucija ka sintetičkoj predobradi: Generisanje i destilacija znanja

Kako se industrija velikih jezičkih modela suočava sa fenomenom poznatim kao „**Zid podataka**” (**Data Wall**), tačkom u kojoj je iscrpljen sav visokokvalitetni ljudski sadržaj dostupan na internetu fokus predobrade se radikalno pomera. Umesto oslanjanja na sirove, često kontaminirane podatke, moderni pajplajni koriste najnaprednije modele za aktivno kreiranje i restrukturiranje trening setova.

7.1. Destilacija podataka (*Data Distillation*) i Teacher-Student dinamika

Destilacija podataka predstavlja proces u kojem ekstremno veliki i moćni modeli (tzv. *Teacher models*, npr. *GPT-5* ili ekvivalentni sistemi iz 2026. godine) generišu visokokvalitetne odgovore, objašnjenja i rešenja problema koji se potom koriste za obučavanje manjih, efikasnijih modela (*Student models*). Ova tehnika rešava dva ključna problema predobrade:

- **Konzistentnost formata:** Sintetički podaci su uvek savršeno formatirani, bez *HTML* šuma ili *OCR* grešaka.
- **Gustoća informacija:** Dok prosečan veb-tekst sadrži mnogo praznog hoda, destilovani podaci su dizajnirani da u svakom tokenu nose maksimalnu količinu logičkih informacija.

7.2. Samoispravljanje (*Self-Correction*) i automatizovano rezonovanje

Jedan od najnaprednijih oblika predobrade danas je generisanje podataka kroz proces samoispravljanja. U ovom scenariju, model generiše početni skup podataka (npr. rešenja matematičkih zadataka), a zatim putem posebnih algoritama za proveru logike (poput *Chain-of-Thought* verifikacije) sam identifikuje greške u sopstvenom razmišljanju. Konačni set podataka koji ulazi u trening korpus sadrži samo verifikovane putanje razmišljanja. Na taj način, predobrada više nije samo filtriranje teksta, već filtriranje logičkih procesa. Rezultat je model koji uči ne samo šta je tačan odgovor, već i kako se do njega dolazi bez logičkih grešaka.

7.3. Dinamičko učenje po planu (*Curriculum Learning*)

Curriculum Learning predstavlja pedagoški pristup u kojem se podaci modelu ne serviraju nasumično, već u strogo definisanom redosledu težine. Ovaj proces se odvija u realnom vremenu tokom faze predobrade:

1. **Inicijalna faza:** Model se izlaže jednostavnim, sintetički generisanim rečenicama i osnovnim konceptima (nivo "osnovne škole").
2. **Srednja faza:** Algoritmi za procenu znanja identifikuju da je model savladao bazu, i tada mu sistem za predobradu otključava kompleksnije semantičke strukture i stručnu literaturu.
3. **Napredna faza:** Model se suočava sa najtežim logičkim zagonetcima i specifičnim domenima (kodiranje, kvantna fizika).

Ovaj pristup drastično smanjuje vreme potrebno za obučavanje, jer model ne gubi računarske resurse na pokušaje razumevanja kompleksnih koncepata pre nego što je savladao osnove.

7.4. Rizik od urušavanja modela (*Model Collapse*)

Kao ključni izazov ovog *state-of-the-art* pristupa preobardi jeste ***Model Collapse***. To je fenomen gde model, učeći isključivo na sintetičkim podacima (koje su generisali prethodni modeli), polako gubi kontakt sa stvarnim svetom i zaboravlja retke, ali istinite informacije koje se nalaze samo u ljudskom govoru. Zbog toga moderna predobrada u 2026. godini podrazumeva pažljivo balansiranje: održavanje odnosa od oko **20-30% autentičnih ljudskih podataka** naspram sintetički generisanog jezgra, kako bi se očuvala kreativnost i širina znanja modela.

8. Zaključak

Put od sirovog, neobrađenog internet šuma do visoko rafiniranih, semantički bogatih korpusa predstavlja najznačajniju promenu paradigme u razvoju veštačke inteligencije u poslednjih nekoliko godina. Princip ***Garbage In, Garbage Out*** evoluirao je iz prostog tehničkog upozorenja u centralnu stratešku odrednicu industrije: dok su rani modeli počivali na kvantitetu i pukoj statističkoj sili, moderna AI revolucija 2026. godine temelji se na selekciji i inteligentnoj sintezi informacija. Kroz analizu algoritama poput ***MinHash*** i ***LSH***, pokazno je kako se rešava problem redundanse na nivou triliona tokena, dok uvođenje semantičkih modela i ***LLM-as-a-Judge*** metodologije transformiše proces filtriranja iz pasivnog čišćenja u aktivnu potragu za udžbeničkim kvalitetom. Iako prelazak na sintetičke podatke, destilaciju znanja i ***Curriculum Learning*** vodi ka efikasnijim i moćnijim sistemima, fenomen ***Model Collapse-a*** služi kao stalno podsećanje da je autentičan ljudski izraz ostaje nezamenljiv temelj i etički kompas u digitalnom svetu podataka. Na kraju, uspeh budućih generacija velikih jezičkih modela neće se meriti samo brojem parametara ili utrošenim kilovat-satima, već preciznošću kuracije koja omogućava da mašina iz nepreglednog šuma informacija destiluje suštinsko ljudsko znanje, logiku i vrednosti.

LITERATURA

- [1] <https://machinelearningmastery.com/building-a-decoder-only-transformer-model-for-text-generation/>
- [2] <https://livebook.manning.com/wiki/categories/llm/causal+attention>
- [3] <https://arxiv.org/abs/2005.14165>
- [4] <https://arxiv.org/abs/2307.09288>
- [5] <https://arxiv.org/abs/2204.02311>
- [6] <https://arxiv.org/html/2503.10079v1>
- [7] WanJuan-CC: A Safe and High-Quality Open-sourced English Webtext Dataset
- [8] <https://openreview.net/forum?id=ak0vIKTkpx>
- [9] <https://tdan.com/data-speaks-for-itself-the-shift-from-syntactic-to-semantic-data-curation/31967>
- [10] <https://arxiv.org/abs/2306.08020>
- [11] <https://arxiv.org/abs/2306.11644>
- [12] <https://arxiv.org/abs/2410.04055>
- [13] <https://arxiv.org/abs/2406.04284>
- [14] <https://arxiv.org/abs/2101.10382>